



Wellington Carlos da Rosa Nascimento

**Valor da Informação e Machine Learning na
Avaliação Econômica de Projetos de E&P**

Proposta de Tese de Doutorado

Proposta de Tese apresentada como requisito parcial para obtenção do título de Doutor pelo Programa de Pós-graduação em Engenharia Elétrica, do Departamento de Engenharia Elétrica da PUC-Rio.

Orientador : Prof. Marco Aurélio C. Pacheco

Coorientador: Prof. Marco Antonio G. Dias

Resumo

Nascimento, Wellington Carlos da Rosa; Pacheco, Marco Aurélio C.; Dias, Marco Antonio G.. **Valor da Informação e Machine Learning na Avaliação Econômica de Projetos de E&P**. Rio de Janeiro, 2025. 44p. Proposta de Tese de Doutorado – Departamento de Engenharia Elétrica, Pontifícia Universidade Católica do Rio de Janeiro.

Projetos de Exploração e Produção (E&P) envolvem elevada incerteza geológica e de mercado. Métodos tradicionais de avaliação, como o Fluxo de Caixa Descontado, não capturam o valor da flexibilidade gerencial. Nesse contexto, o **Valor da Informação** (VoI) quantifica os benefícios de reduzir incertezas, enquanto as **Opções Reais** (ROA) avaliam a flexibilidade de adiar, expandir ou abandonar projetos. O **Aprendizado de Máquina** (ML) complementa essas abordagens ao reduzir custos computacionais com modelos proxy, apoiar a análise de VoI identificando informações críticas e aproximar soluções de ROA por meio de algoritmos de regressão e reforço. Assim, a integração de ML, VoI e ROA permite decisões mais robustas, aumentando o valor econômico e reduzindo riscos em projetos de E&P.

Sumário

1	Introdução	7
1.1	Objetivos	7
1.2	Publicações	7
1.3	Organização da Proposta	7
2	Fundamentação Teórica	8
2.1	Valor da Informação	9
2.1.1	Quantificando a Informação	9
2.1.2	Etapas no Cálculo do VOI	11
2.1.3	VOI e o Problema TALL-N	14
2.1.4	Medida de Aprendizagem η^2	19
2.1.5	Valor da Informação Sequencial	24
2.1.6	Modelo de Decisão Sequencial	28
2.2	Valor da Flexibilidade	35
2.3	Incertezas Técnicas	36
2.4	Incertezas do Mercado	36
2.5	Redes Neurais	36
2.6	Redes Neurais Convolucionais	37
3	Estado da Arte	38
4	Resultados Preliminares	39
5	Próximos Passos	40
6	Conclusão	41
	Referências Bibliográficas	42
A	Trabalhos Publicados	44

Lista de figuras

Figura 2.1	Árvore de decisão genérica do VoI. Fonte: [01].	12
Figura 2.2	Inversão da árvore de decisão. Fonte: [01].	13
Figura 2.3	Problema TALL-N com preferência inicial de risco. Fonte: [04].	15
Figura 2.4	Máximo valor de RVOI em função de $c = \frac{\mu-v}{\sigma}$.	17
Figura 2.5	Valor de RVOI em função de $c = \frac{\mu-v}{\sigma}$.	18
Figura 2.6	VOI em função de η^2 .	20
Figura 2.7	Valor empírico e teórico de $\eta^2(X S)$ para diferentes níveis de correlação ρ .	23
Figura 2.8	Decomposição da variância total em função da correlação ρ .	23
Figura 2.9	Ilustração parcial de uma campanha de perfuração sequencial. Fonte [10].	27
Figura 2.10	Representação esquemática do SDM. Fonte [11].	29
Figura 2.11	Representação esquemática alternativa do SDM. Fonte [12].	29
Figura 2.12	Árvore de decisão representando um simples SDM. Fonte [11].	31
Figura 2.13	Exemplo do processo SDP. Fonte [11].	32
Figura 2.14	Nó de decisão genérico. Fonte [11].	32
Figura 2.15	Análise simples da política ótima para três poços. Fonte [11].	34
Figura 2.16	Valor da flexibilidade. Fonte [11].	35
Figura 2.17	3D Egg model	36
Figura 4.1	Arquitetura da Rede	39

Lista de tabelas

Tabela 3.1	A Risk-Neutral Version of BDH's Base Case Analysis	38
------------	--	----

Lista de Abreviaturas

VOI – *Value of Information*

VPL – Valor Presente Líquido

NPV – *Net Present Value*

VOPI – *Value of Perfect Information*

EVPI – *Expected Value of Perfect Information*

EVII – *Expected Value of Imperfect Information*

TALL-N – *Two-Action Linear-Loss with Normal priors*

RVOI – *Relative Value of Information*

VOSI – *Value of Sequential Information*

SDM – *Sequential Decision Model*

SDP – *Stochastic Dynamic Programming*

1

Introdução

This is the first chapter. In this chapter, let's have a nice image mais teste θ :

1.1

Objetivos

1.2

Publicações

1.3

Organização da Proposta

2

Fundamentação Teórica

O desenvolvimento de campos de petróleo ocorre sob condições de incerteza associadas à caracterização geológica do reservatório, bem como a parâmetros econômicos e tecnológicos. Essas incertezas influenciam diretamente o valor do projeto. O baixo desempenho de algumas empresas de petróleo é consequência do reduzido investimento aplicado em ferramentas de suporte à decisão e da ausência de investimentos suficientes para estimar corretamente o retorno do projeto, o que pode levar tanto à superestimação dos ganhos quanto à subestimação das perdas.

Três tipos de riscos no desenvolvimento de campos de petróleo devem ser considerados no processo de tomada de decisão:

1. **perda de oportunidade:** um prospecto é considerado não econômico e abandonado, quando na verdade seria viável economicamente;
2. **desenvolvimento não econômico:** um campo inviável é desenvolvido por ter sido erroneamente considerado econômico;
3. **desenvolvimento subótimo:** um campo é desenvolvido, mas gera retorno inferior ao máximo possível, que poderia ser obtido se o modelo de reservatório correto tivesse sido considerado.

O risco envolvido na fase de desenvolvimento pode ser reduzido se informações adicionais forem obtidas para diminuir ou até eliminar uma determinada incerteza. Entretanto, a aquisição de informação está diretamente associada a custos. Por isso, antes de decidir pela obtenção de informação, sugere analisar dois aspectos: se vale a pena adquirir informação adicional e se tal informação é de fato capaz de melhorar o processo decisório. Uma ferramenta consistente que pode ser utilizada como critério no processo de decisão é o *Valor da Informação (VOI)*, que combina incertezas do reservatório com suas potenciais consequências econômicas.

2.1

Valor da Informação

A prática profissional em engenharia de petróleo e geociências está fortemente associada à aquisição de informações, obtidas sob diversas formas e em múltiplos contextos. O termo informação é usado aqui em um sentido amplo, incluindo coleta de dados, realização de estudos técnicos, contratação de consultores, execução de testes diagnósticos, etc. A expectativa é que a redução da incerteza aumente a chance de que nossas decisões resultem no desfecho desejado. De fato, a única outra razão válida para coletar informação ou realizar análises técnicas é o cumprimento de exigências regulatórias.

A questão fundamental em qualquer processo de coleta de informação é se a redução esperada da incerteza compensa o custo de se obter a informação. A técnica de *Value of Information* (VOI), em português **Valor da Informação**, é projetada justamente para responder a essa questão [01].

2.1.1

Quantificando a Informação

O objetivo do VOI é estimar o valor de um exercício proposto de coleta de informações, de modo que a decisão de implementá-lo ou não seja feita em bases econômicas. Para que a informação seja valiosa, deve existir uma dependência probabilística entre a informação e os resultados do evento incerto de interesse (relevância). Além disso, o evento de interesse deve impactar suficientemente uma métrica de decisão a ponto de podermos alterar nossa decisão (materialidade). Finalmente, seu valor deve exceder o seu custo, caso em que a regra implícita de investimento recomenda adquirir a informação (valor maior que o custo). O custo de aquisição da informação depende da natureza da informação. O cálculo dos custos inclui salários da equipe, custos de oportunidade e custos diretos óbvios.

O VOI pode ser entendido como o valor atribuído às probabilidades atualizadas. Para calcular esse valor, são necessárias as seguintes informações:

1. **Probabilidade atuais**, ou *a priori*, dos possíveis resultados que a variável pode assumir (por exemplo, 30% de chance de o fator de recuperação ser baixo e 70% de chance de ser alto).
2. **Estimativas de confiabilidade (verossimilhança)** da eficácia da informação em predizer os resultados (por exemplo, quando o fator de recuperação é conhecido como alto, estudos de simulação de reservatórios 3D indicam corretamente “alto” em 80% dos casos).

3. **Valores de projeto em termos monetários** para cada uma das possíveis combinações de resultados (por exemplo, VPL de +600 milhões de USD se o fator de recuperação for alto e -100 milhões de USD se for baixo).

Embora os valores de projeto possam ser derivados por meio de análise determinística, recomenda-se o uso do Valor Presente Líquido (VPL, do inglês *Net Present Value* – *NPV*) esperado, obtido via simulação de Monte Carlo de outras incertezas, devido às complexas inter-relações frequentemente envolvidas.

O cálculo do VOI costuma ser representado em árvores de decisão, pois elas trazem clareza ao processo. O procedimento envolve comparar duas árvores:

- A primeira árvore representa o valor esperado do projeto com as probabilidades atuais.
- A segunda árvore representa o valor esperado do projeto com as probabilidades atualizadas, resultantes da aquisição da informação.

A diferença entre os dois valores fornece o **VOI esperado**. Utilizamos o termo **esperado** em seu sentido matemático estrito — o valor obtido ao aplicar repetidamente a metodologia do VoI em diversas decisões. Antes de detalhar o procedimento de cálculo, consideremos primeiro alguns limites intuitivos do VoI:

- **Limite inferior:** Se a informação não altera a decisão, seu valor esperado é zero, independentemente do custo.
- **Limite superior:** A informação perfeita (sem erro) fornece o valor máximo possível, denominado **Valor Esperado da Informação Perfeita** (EVPI). Este limite superior serve como referência: nenhum processo de aquisição de informação pode exceder o EVPI.

O cálculo do EVPI não depende da existência de métodos perfeitos de aquisição de informação, mas sim de fornecer um *benchmark* para avaliar qualquer processo de coleta de informação. Se o custo do processo excede o EVPI, não há motivo para prosseguir com a proposta. Se o EVPI indicar que vale a pena avançar, procede-se ao cálculo do **Valor Esperado da Informação Imperfeita** (EVII), que leva em conta a confiabilidade da informação obtida.

2.1.2

Etapas no Cálculo do VOI

Os principais procedimentos para conduzir um estudo de VOI são descritos a seguir. Posteriormente, estes passos serão ilustrados por meio de uma decisão simplificada.

1. Calcular o valor esperado da decisão a ser tomada no estado atual (isto é, sem a informação). Este cálculo é denominado **valor do projeto base**.
2. Formular a estrutura da situação de decisão de modo a incluir a nova informação. Isso é feito adicionando um novo ramo ao primeiro nó da árvore de decisão para representar a escolha de adquirir informação. Este ramo leva a um nó de incerteza, cujo evento incerto corresponde aos resultados do exercício de coleta de informação.
3. Calcular o valor da informação perfeita. Se o EVPI for insignificante ou menor que o custo de aquisição da informação, não se deve coletar a informação e deve-se escolher a alternativa de maior valor no projeto base. Caso contrário, prosseguir para o Passo 4.
4. Calcular o valor do projeto com a informação real, ou imperfeita. Este passo é subdividido em:
 - (a) Estimar as probabilidades de verossimilhança, isto é, $P(\text{informação diz} \mid \text{mundo real})$.
 - (b) Calcular as probabilidades atualizadas (posteriores) pelo Teorema de Bayes.
 - (c) Inserir as probabilidades atualizadas na árvore de decisão e resolver para obter o valor do projeto.
5. Calcular o EVII, obtido pela diferença entre os valores dos Passos 4 e 1. Comparar essa diferença com o custo de aquisição da informação.
6. Realizar uma análise de sensibilidade para verificar a robustez da decisão diante de variações nas probabilidades e nos *payoffs*.

A parte mais complexa do procedimento anterior é o Passo 2 — garantir que a formulação da situação de decisão inclua a informação antecipada. Para ilustrar, considere o seguinte exemplo simplificado. Suponha uma decisão binária: realizar uma ação (por exemplo, perfurar um poço) ou não. Denotamos essas alternativas como D_1 e D_2 , ver Figura 2.1.




Figura 2.1: Árvore de decisão genérica do VoI. Fonte: [01].

Há um evento incerto B com dois possíveis resultados: B_1 e B_2 (por exemplo, o poço é comercial ou não). As probabilidades desses resultados são $P(B_1)$ e $P(B_2)$. Se escolhermos D_1 , o valor do projeto é $NPV(B_1)$ ou $NPV(B_2)$, dependendo do resultado. Se escolhermos D_2 , assumimos payoff igual a USD 0. Esse caso constitui o *projeto base* (Passo 1). Para incluir a opção de coletar informação adicional, adicionamos uma terceira alternativa D_A ao nó inicial da árvore, indicando a decisão de adquirir informação, A . Os possíveis resultados dessa informação, A_1 ou A_2 , são conhecidos por serem dependentes dos resultados de interesse, B_1 e B_2 . Um exemplo seria um levantamento sísmico 3D, cujos resultados podem ser “Bright Spot” (A_1) ou “No Bright Spot” (A_2). Nesse ponto, não conhecemos as probabilidades de A_1 ou A_2 , mas uma vez conhecidas, retomamos a decisão original. O problema de decisão é então modelado replicando a árvore do projeto base em cada ramo correspondente a A_1 e A_2 . As probabilidades de B , por estarem relacionadas às probabilidades de A , são indicadas como probabilidades condicionais. Por exemplo, se o levantamento sísmico (A_1) indicar “Bright Spot” e decidirmos executar o projeto D_1 , o poço poderá ser comercial com probabilidade $P(\text{Comercial} | A_1)$ ou não comercial com probabilidade $P(\text{Não Comercial} | A_1)$. Dessa forma, a situação de decisão passa a incluir a opção de coletar informação. O próximo passo é calcular as probabilidades necessárias e resolver a árvore normalmente. Supondo que tenhamos dados de confiabilidade sobre a eficácia de “Bright Spots” na previsão de poços comerciais, podemos combiná-los com as probabilidades a priori por meio do processo de *tree-flipping* (inversão

da árvore de decisão) que permite combinar probabilidades a priori com informações de confiabilidade, conforme ilustrado na Figura 2.2.




Figura 2.2: Inversão da árvore de decisão. Fonte: [01].

A soma das probabilidades dos possíveis resultados da aquisição de informação, $P(A_1)$ e $P(A_2)$, corresponde à probabilidade total. Esse é justamente o denominador do **Teorema de Bayes**, que pode ser escrito de forma geral como:

$$P(B_i | A) = \frac{P(A | B_i) P(B_i)}{\sum_{j=1}^n P(A | B_j) P(B_j)}. \quad (2-1)$$

No caso específico do exemplo acima, obtemos as seguintes probabilidades atualizadas:

$$P(B_1 | A_1) = \frac{P(A_1 | B_1) P(B_1)}{P(A_1 | B_1) P(B_1) + P(A_1 | B_2) P(B_2)} \quad (2-2)$$

$$P(B_2 | A_1) = \frac{P(A_1 | B_2) P(B_2)}{P(A_1 | B_1) P(B_1) + P(A_1 | B_2) P(B_2)} \quad (2-3)$$

$$P(B_1 | A_2) = \frac{P(A_2 | B_1) P(B_1)}{P(A_2 | B_1) P(B_1) + P(A_2 | B_2) P(B_2)} \quad (2-4)$$

$$P(B_2 | A_2) = \frac{P(A_2 | B_2) P(B_2)}{P(A_2 | B_1) P(B_1) + P(A_2 | B_2) P(B_2)} \quad (2-5)$$

Uma questão central na análise de VOI é a origem das probabilidades a priori e de verossimilhança. Em geral, tais probabilidades derivam de avaliações subjetivas, baseadas no conhecimento dos especialistas sobre a situação ou dados disponíveis. A subjetividade é inerente à análise de decisão: os modelos

são aproximações da realidade e frequentemente dependem de julgamentos sem dados empíricos diretos.

Priors: As distribuições a priori descrevem o estado de conhecimento sobre o evento incerto antes da obtenção de novas informações. Essa interpretação como "grau de crença" é amplamente aceita e permite o uso de qualquer fonte de conhecimento ou experiência relevante. Ser capaz de avaliar corretamente distribuições a priori é uma habilidade essencial para engenheiros e geocientistas.

Likelihood: A função de verossimilhança representa a probabilidade condicional da informação observada, dado o evento de interesse. Na prática, pode estar relacionada à qualidade ou à confiabilidade da informação adquirida (por exemplo, sísmica, perfis, testes de pressão). A construção da verossimilhança envolve considerar tanto a acurácia dos dados quanto o viés de interpretação. Quando disponíveis, dados históricos podem apoiar a estimação dessas probabilidades, embora sejam raramente formalizados. Em muitos casos, utilizam-se bandas de confiabilidade e análises de sensibilidade para avaliar a robustez das decisões.

Quatro critérios principais determinam se a aquisição de informação é valiosa em um estudo de VOI ([02], [03]):

- **Observável:** Os resultados da coleta de informação devem ser conhecidos antes da decisão.
- **Relevante:** A informação deve ter o potencial de alterar as crenças sobre a incerteza associada ao problema.
- **Material:** A informação deve ser capaz de modificar a decisão final.
- **Econômica:** O valor esperado da informação deve exceder o custo de adquiri-la.

O método de VOI garante que esses critérios sejam satisfeitos e pode ser aplicado a decisões de qualquer complexidade. Entretanto, modelos mais sofisticados podem ser necessários quando múltiplas incertezas ou distribuições contínuas estão envolvidas.

2.1.3

VOI e o Problema TALL-N

O VOI é definido como o valor máximo que o tomador de decisão deveria pagar por informação adicional relevante. Sob a hipótese de neutralidade ao risco, o VOI é dado por [03]:

$$VOI = \mathbb{E}[\text{valor com informação}] - \mathbb{E}[\text{valor sem informação}]. \quad (2-6)$$

Se a informação adicional for perfeita, essa quantidade é denominada **Valor da Informação Perfeita** (VOPI) que representa o limite superior de qualquer atividade de coleta de informação. Conforme a terminologia usada na subseção (2.1.1) temos EVPI (Valor Esperado da Informação Perfeita) ou EVII (Valor Esperado da Informação Imperfeita). O valor esperado com informação só pode ser maior do que o valor sem informação se a decisão puder ser alterada em função da informação revelada. Caso o tomador de decisão adote a mesma ação independentemente do resultado do teste, então $VOI = 0$, tornando a coleta de informação inútil para o problema decisório.

Um problema interessante na análise do VOI é o **problema TALL-N** (*Two-Action Linear-Loss with Normal priors*) que considera um tomador de decisão diante de duas alternativas:

- a_0 : alternativa segura, com payoff constante v ;
- a_1 : alternativa arriscada, com payoff incerto descrito por uma variável aleatória $\tilde{x}$ com média μ e desvio-padrão σ .

Se $\mu < v$, o decisor escolhe a_0 ; se $\mu > v$, escolhe a_1 ; e se $\mu = v$, encontra-se indiferente. O valor esperado sem informação adicional é dado por:

$$\mathbb{E}[\text{valor sem informação}] = \max(v, \mu). \quad (2-7)$$

A Figura 2.3 ilustra o problema TALL-N, onde a variável aleatória $\tilde{x}$ é assumida como normalmente distribuída. A padronização $z = \frac{x-\mu}{\sigma}$ permite definir o coeficiente de divergência:

$$c = \frac{\mu - v}{\sigma}, \quad (2-8)$$

que representa a distância entre as duas alternativas em unidades de desvio-padrão.




Figura 2.3: Problema TALL-N com preferência inicial de risco. Fonte: [04].

A **informação perfeita** permite ao decisor sempre escolher a melhor alternativa conforme o verdadeiro estado da natureza. Assim, o EVPI é definido

por:

$$EVPI = E[\max(v, \tilde{x})] - \max(v, \mu). \quad (2-9)$$

No caso normal (TALL-N), obtém-se a seguinte forma fechada [04]:

$$EVPI = \begin{cases} \sigma [\phi(c) - c \Phi(-c)], & \mu \geq v, \\ \sigma [\phi(c) + c \Phi(c)], & \mu < v, \end{cases} \quad (2-10)$$

em que $\phi(\cdot)$ é a densidade da normal padrão e $\Phi(\cdot)$ sua função de distribuição acumulada.

Quando a **informação é imperfeita**, mas correlacionada com o payoff incerto, utilizamos o EVII. Considere um sistema de informação Θ_ρ , cujo sinal θ é normalmente distribuído e correlacionado com $\tilde{x}$ por um coeficiente de correlação $\rho > 0$. Nesse caso, a média condicional é dada por $E[\tilde{x} | \theta] = \mu + \rho\sigma\theta$ que será maior que v enquanto $\theta > (v - \mu)/(\rho\sigma) = -\rho^{-1}c$. Portanto, o EVII é definido por:

$$EVII = E[\max(v, E[\tilde{x} | \theta])] - \max(v, \mu), \quad (2-11)$$

e pode ser escrito na forma fechada como [04]:

$$EVII = \begin{cases} \rho\sigma [\phi(\rho^{-1}c) - \rho^{-1}c \Phi(-\rho^{-1}c)], & \mu \geq v, \\ \rho\sigma [\phi(\rho^{-1}c) + \rho^{-1}c \Phi(\rho^{-1}c)], & \mu < v. \end{cases} \quad (2-12)$$

O valor de EVII dado pela Equação (2-12) é o valor esperado da distribuição que descreve a incerteza no VOI [15]. Quando a correlação é perfeita ($\rho = 1$), temos o caso de informação perfeita, cujos resultados são equivalentes ao EVPI. Por outro lado, a informação imperfeita, com correlação ρ , pode ser interpretada como equivalente ao valor da informação perfeita, mas com um desvio-padrão ajustado $\sigma_{\text{ajustado}} = \rho\sigma$, ou seja:

$$\rho^{-1}c = \frac{\mu - v}{\rho\sigma} \quad (2-13)$$

comparar com a Equação (2-8). Isso significa que a qualidade da informação imperfeita pode ser vista como se fosse informação perfeita, porém mais “difusa”, já que a incerteza é reduzida proporcionalmente a ρ .

O valor do EVII é sempre limitado superiormente pelo EVPI, aproximando-se dele quando $\rho \rightarrow 1$ e tendendo a zero quando $\rho \rightarrow 0$. No limite, quando $c \rightarrow \infty$, obtém-se [04]:

$$\lim_{c \rightarrow \infty} RVOI_\rho^* = \rho^2, \quad (2-14)$$

onde o sobrescrito $*$ indica que este é o valor máximo do RVOI para um determinado c . Assim, define-se o *Relative Value of Information* (RVOI) como

a razão entre EVII e EVPI:

$$RVOI_{\rho}^* = \frac{EVII}{EVPI} = \rho^2. \quad (2-15)$$

Portanto, o RVOI expressa diretamente a fração do valor da informação imperfeita em relação ao valor da informação perfeita, sendo determinado pelo quadrado do coeficiente de correlação, isto é, ρ^2 [04]. Na referência [05] temos também a demonstração que $RVOI = \rho^2$ no contexto de perda quadrática e função de regressão linear.

Dado um valor específico de c , o RVOI atinge seu valor máximo quando $c = \sigma/2R$, onde R representa a *risk tolerance* do tomador de decisão e σ o desvio-padrão. Nessa condição, a informação imperfeita possui o maior valor relativo em comparação com a informação perfeita, correspondendo ao caso em que o tomador de decisão está indiferente. Assim, o valor máximo do RVOI é expresso por:

$$RVOI_{\rho}^* = \frac{\ln [2\Phi(-\rho c)]}{\ln [2\Phi(-c)]}, \quad (2-16)$$

Na Figura 2.4 é apresentado o gráfico do valor máximo de $RVOI^*$ em função do coeficiente de divergência c . Observa-se que, para diferentes valores do coeficiente de correlação ρ , o comportamento de $RVOI^*$ evidencia a importância relativa da informação imperfeita em comparação à informação perfeita. Além disso, a figura permite analisar os valores-limite que fornecem interpretações intuitivas sobre o valor da informação em diferentes cenários de risco e preferência do tomador de decisão.




Figura 2.4: Máximo valor de RVOI em função de $c = \frac{\mu-v}{\sigma}$.

Importante ressaltar que é possível calcular outros dois limites para $RVOI^*$, os quais podem ser visualizados na Figura 2.4. Quando $c \rightarrow 0$, temos

que $RVOI_\rho^* \rightarrow \rho$, conforme o problema TALL-N, onde $RVOI_\rho = \rho$. Por outro lado, quando $c \rightarrow -\infty$, obtém-se $RVOI_\rho^* \rightarrow 1$, o que indica que um tomador de decisão avesso ao risco pode valorizar a informação imperfeita quase tanto quanto a informação perfeita, caso a alternativa de *status quo* seja significativamente melhor que a alternativa arriscada. No entanto, o limite que nos interessa é o expresso pela Equação (2-15), pois fornece uma interpretação interessante para o seguinte resultado:

$$EVII = \eta^2 \cdot EVPI \quad (2-17)$$

Abordaremos essa relação na subseção seguinte, antes, vamos analisar o RVOI no caso geral para o problema TALL-N, razão entre as Equações (2-12) e (2-10), que é dado por [04]:

$$\frac{EVII}{EVPI} = \begin{cases} \rho, & \mu = v \\ \frac{\rho \phi(\rho^{-1}c) - c \Phi(-\rho^{-1}c)}{\phi(c) - c \Phi(-c)}, & \mu > v \\ \frac{\rho \phi(\rho^{-1}c) + c \Phi(\rho^{-1}c)}{\phi(c) + c \Phi(c)}, & \mu < v \end{cases} \quad (2-18)$$

Assim, observa-se que RVOI depende do coeficiente de correlação ρ e do coeficiente de divergência c . No caso em que $\mu = v$, o valor relativo da informação imperfeita em relação à informação perfeita é simplesmente ρ . Já quando $\mu > v$ ou $\mu < v$, a relação passa a depender da interação entre ρ e c . A Figura 2.5 mostra o comportamento de RVOI em relação ao coeficiente de divergência c , dado pela Equação (2-18):




Figura 2.5: Valor de RVOI em função de $c = \frac{\mu-v}{\sigma}$.

De forma geral, conforme Figura 2.5, o comportamento de $\frac{EVII}{EVPI}$ é

simétrico em torno de $c = 0$, diminuindo rapidamente conforme o valor absoluto de c aumenta. Isso significa que, à medida que cresce a divergência entre as alternativas, o valor relativo da informação imperfeita cai de forma significativa, mesmo para correlações elevadas.

2.1.4

Medida de Aprendizagem η^2

A **medida de aprendizagem** η^2 , introduzido por [06], também conhecida por **fator de transferência de valor** [07], pode ser entendido como uma medida que quantifica a efetividade da informação adquirida na redução da incerteza do processo decisório. Esse parâmetro está diretamente associado à redução percentual esperada da variância de uma variável de interesse.

Sejam duas variáveis aleatórias X e S , ambas com médias e variâncias finitas e definidas em um mesmo espaço de probabilidade. A variável X representa, por exemplo, uma incerteza técnica relevante, como o volume de óleo não varrido em uma região do reservatório, e S corresponde à nova informação adquirida (por exemplo, dados sísmicos *time-lapse*). A medida de aprendizagem é então definida por ([06], [07], [08]):

$$\eta^2(X | S) = \frac{\text{Var}[X] - \mathbb{E}[\text{Var}(X | S)]}{\text{Var}[X]}. \quad (2-19)$$

A Equação (2-19) expressa a redução percentual da variância de X proporcionada pela informação S , em relação à variância original sem informação adicional. Em outras palavras, mede o quanto a incerteza é reduzida em termos esperados após a obtenção da nova informação. O valor de η^2 varia entre 0 e 1. Quando $\eta^2 = 0$, a informação é totalmente não informativa, não reduzindo a incerteza; nesse caso, o VOI tende a zero. Por outro lado, quando $\eta^2 = 1$, toda a incerteza é eliminada, o que corresponde ao caso de informação perfeita, em que $VOI = EVPI$.

Na prática, o cálculo exato de η^2 pode ser complexo, pois depende tanto da distribuição de probabilidade da variável X quanto da probabilidade condicional $X|S$. Contudo, sua interpretação é intuitiva: trata-se de uma métrica que indica o ganho esperado de informação em termos de redução da incerteza, permitindo avaliar a relevância e a efetividade da aquisição de novos dados no contexto da tomada de decisão.

Com base no exposto até aqui, podemos considerar que o VOI é equivalente ao EVII, o qual deve ser uma função de η^2 e do EVPI, conforme estabelecido na Equação (2-17). Dessa forma, é possível obter o gráfico do VOI em função de η^2 para diferentes valores de μ (média da variável aleatória):
i) $\mu < v$, a escolha ótima do tomador de decisão é a_0 (alternativa segura, com

payoff constante v); **ii**) $\mu > v$, a escolha ótima é a_1 (alternativa arriscada, com *payoff* incerto); **iii**) $\mu = v$, o tomador de decisão encontra-se indiferente entre as duas alternativas. Vale ressaltar que o valor esperado do tomador de decisão sem informação adicional é dado por $\max(v, \mu)$, conforme Equação (2-7) .

A Figura 2.6 apresenta a relação entre VOI e η^2 , ilustrando o como o valor da informação depende da redução esperada da variância da variável de interesse em cada um dos cenários decisórios.




Figura 2.6: VOI em função de η^2 .

Ressalta-se que o comportamento observado no gráfico da Figura 2.6 é semelhante ao encontrado em [06], [07] e [15]. É sabido também que a curva muda o comportamento, sem alterar a concavidade, para diferentes valores do *payoff*. Em particular, em [07] é apresentada uma função VOI cujo comportamento linear em relação a η^2 é dado por:

$$VOI \equiv VOII = \begin{cases} VOPI [a + (1 - a)\eta^2], & \text{para } \eta^2 \geq \frac{-a}{1 - a}, \\ 0, & \text{para } \eta^2 < \frac{-a}{1 - a}, \end{cases} \quad (2-20)$$

onde a é um parâmetro linear do modelo (consideraram $a = -0.1$), VOII o valor da informação imperfeita, VOPI o valor da informação perfeita e η^2 a medida de aprendizagem.

A medida de aprendizagem η^2 é uma medida fundamental também em um contexto bayesiano. Ela expressa a fração da variância total de uma variável aleatória X (estado verdadeiro) que é reduzida (ou explicada) após a observação de uma variável informativa S . Formalmente, sua definição geral é dada pela Equação (2-19), que pode ser reescrita como:

$$\eta^2(X|S) = \frac{\text{Var}[X] - \mathbb{E}[\text{Var}(X|S)]}{\text{Var}[X]} = \frac{\text{Var}(\mathbb{E}[X|S])}{\text{Var}[X]}. \quad (2-21)$$

A Equação 2-21 deriva diretamente da *lei da variância total*:

$$\text{Var}[X] = \mathbb{E}[\text{Var}(X|S)] + \text{Var}(\mathbb{E}[X|S]), \quad (2-22)$$

a qual separa a variância total em duas componentes: (i) a variância média residual que representa a incerteza remanescente após observar S ; e (ii) a variância explicada pela informação contida em S .

Suponha que X e S sejam variáveis aleatórias normais padronizadas e correlacionadas, tal que:

$$\begin{pmatrix} X \\ S \end{pmatrix} \sim \mathcal{N}\left(\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix}\right), \quad (2-23)$$

onde ρ é o coeficiente de correlação linear entre X e S . Assim, para o caso normal bivariado, a distribuição condicional de X dado $S = s$ é também normal:

$$X|S = s \sim \mathcal{N}(\rho s, 1 - \rho^2). \quad (2-24)$$

As propriedades de esperança e variância condicionais são dadas por:

$$\mathbb{E}[X|S] = \rho S, \quad \text{Var}(X|S) = 1 - \rho^2. \quad (2-25)$$

Sabendo que $\text{Var}[X] = \text{Var}[S] = 1$, podemos calcular:

$$\text{Var}(\mathbb{E}[X|S]) = \text{Var}(\rho S) = \rho^2 \text{Var}[S] = \rho^2, \quad (2-26)$$

e portanto:

$$\eta^2(X|S) = \frac{\text{Var}(\mathbb{E}[X|S])}{\text{Var}[X]} = \frac{\rho^2}{1} = \rho^2. \quad (2-27)$$

Logo, no caso normal bivariado, a medida de aprendizagem é igual ao quadrado da correlação entre a variável verdadeira X e a informação adquirida S . Essa relação é intuitiva: quanto mais correlacionada a informação S estiver com o estado verdadeiro X , maior será a fração da variância total explicada, e consequentemente, maior o valor potencial da informação.

No modelo TALL-N, analisado na subseção anterior e amplamente utilizado em análise de decisão sob incerteza, a variável de interesse X segue uma distribuição normal a priori:

$$X \sim \mathcal{N}(\mu_0, \sigma_0^2), \quad (2-28)$$

e a informação observada é modelada como uma variável S (por exemplo, um teste sísmico) e afetada por ruído aditivo gaussiano (ruído da observação):

$$S = X + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \sigma_\varepsilon^2). \quad (2-29)$$

Nesse contexto, o fator de transferência de valor é dado por:

$$\eta^2 = \frac{\sigma_0^2}{\sigma_0^2 + \sigma_\varepsilon^2}, \quad (2-30)$$

onde σ_0^2 é a incerteza inicial (a priori), σ_ε^2 é a incerteza da medição (ruído), portanto η^2 mede quanto da incerteza inicial é resolvida pela informação S . Temos também que a correlação linear entre o valor verdadeiro X e a informação observada S é:

$$\rho = \frac{\sigma_0}{\sqrt{\sigma_0^2 + \sigma_\varepsilon^2}}. \quad (2-31)$$

Assim, das Equações (2-30) e (2-31), obtemos a relação direta:

$$\eta^2 = \rho^2. \quad (2-32)$$

Portanto, no contexto do modelo TALL-N, a qualidade da informação é determinada pela correlação entre o valor verdadeiro X e a informação adquirida S . Quanto maior ρ , maior é η^2 e, conseqüentemente, maior é o Valor da Informação.

A Figura 2.7 apresenta o resultado de uma simulação empírica comparando o valor teórico e o valor estimado de $\eta^2(X|S)$ para diferentes níveis de correlação ρ . O código *Python* gera amostras bivariadas normais com correlação controlada e calcula, para cada valor de ρ , a fração da variância total de X explicada por S , utilizando a definição da Equação 2-21.

- Os pontos vermelhos representam os valores empíricos de η^2 , calculados a partir de amostras simuladas.
- A linha azul tracejada mostra os valores teóricos, baseados na relação analítica conforme a Equação 2-32.




Figura 2.7: Valor empírico e teórico de $\eta^2(X|S)$ para diferentes níveis de correlação ρ .

Os resultados empíricos coincidem quase perfeitamente com a curva teórica, confirmando que, para variáveis gaussianas correlacionadas, a proporção da variância explicada pela informação é exatamente o quadrado da correlação. Isso reforça a interpretação de η^2 como uma medida da qualidade da informação: quanto mais forte a correlação, maior a fração de incerteza eliminada.

A Figura 2.8 ilustra graficamente a decomposição da variância total de X em duas componentes: a parcela explicada pela informação ($\text{Var}(\mathbb{E}[X|S])$) e a parcela residual ($\mathbb{E}[\text{Var}(X|S)]$). O eixo horizontal representa a correlação ρ , enquanto o eixo vertical mostra a fração da variância total (normalizada, $\text{Var}[X] = 1$).




Figura 2.8: Decomposição da variância total em função da correlação ρ .

- A curva verde representa a variância explicada pela informação, proporcional a ρ^2 .
- A curva azul representa a variância residual, proporcional a $(1 - \rho^2)$.
- A linha vermelha tracejada indica a variância total normalizada ($\text{Var}[X] = 1$).

À medida que a correlação ρ aumenta, a fração de variância explicada (curva verde) cresce, enquanto a variância residual (curva azul) diminui. Quando $\rho = 0$, toda a incerteza permanece; quando $\rho = 1$, toda a incerteza é eliminada. Essa decomposição ilustra de maneira clara a essência do fator η^2 , representando a proporção da incerteza inicial que é resolvida pela informação disponível.

2.1.5

Valor da Informação Sequencial

A exploração e produção de petróleo envolvem elevados níveis de incerteza geológica, operacional e econômica. Decisões inadequadas na fase de delimitação (*appraisal*) podem levar a investimentos em poços de alto custo com baixo retorno, ou ainda à subexploração de reservas economicamente viáveis. Nesse contexto, o Valor da Informação, conforme visto na seção anterior, surge como uma ferramenta quantitativa essencial para avaliar se a aquisição de novos dados, por meio de poços de avaliação, testes de formação ou métodos geofísicos adicionais, justifica o investimento em função do impacto que tais informações podem ter sobre decisões futuras.

O **Valor da Informação Sequencial** (VOSI, *Value of Sequential Information*) expande o conceito clássico de VOI ao considerar que a informação é adquirida em diferentes estágios, e que as decisões subsequentes podem ser ajustadas de acordo com os resultados parciais já observados. Diferentemente de um VOI estático, que assume um único ponto de coleta de dados antes da decisão final, o VOSI modela um processo dinâmico, no qual o tomador de decisão pode:

- optar por perfurar um poço adicional se os resultados iniciais forem promissores;
- redirecionar o programa de avaliação caso os dados revelem incertezas críticas não previstas;
- abandonar ou postergar o desenvolvimento se os sinais forem negativos.

Essa flexibilidade gera valor adicional, pois permite incorporar **aprendizado progressivo** ao processo de delimitação do campo. A formulação básica do VOI, conforme Equação (2-6), pode ser expressa por:

$$VOI = \mathbb{E}[X | S] - \mathbb{E}[X], \quad (2-33)$$

onde $\mathbb{E}[X | S]$ representa o valor esperado do projeto com informação adicional S , isto é, o valor esperado posterior e, $\mathbb{E}[X]$, represente o valor esperado sem informação, ou seja, valor esperado a priori, que para um problema de decisão, pode ser obtido com [09]:

$$\mathbb{E}[X] = \sum_{i=1}^n \max_{a_i \in A_i} \left\{ \mathbb{E}[v(x_i, a_i)] \right\}, \quad (2-34)$$

onde x_i representa os estados da natureza, $a_i \in A_i$ as alternativas disponíveis e $v(x_i, a_i)$ o valor associado à decisão a_i sob o estado x_i .

Por razões didáticas, vejamos um exemplo retirado de [09]: considere a perfuração de dois poços S_1 e S_2 . Suponha que o tomador de decisão opte pela aquisição da primeira perfuração S_1 , com a possibilidade de posteriormente realizar também a perfuração S_2 . Para alguns resultados obtidos a partir da perfuração do poço S_1 , o decisor pode não considerar necessária a realização da segunda perfuração. Para outros resultados, ele ou ela pode, de fato, optar por realizar a perfuração do poço S_2 . Assim, o valor de um esquema de perfuração sequencial não pode ser inferior ao valor obtido ao realizar ambas as perfurações de uma só vez, isto é, uma estratégia estática de perfuração. Um decisor neutro ao risco pode determinar a melhor sequência de perfuração ao maximizar o valor esperado. No caso de dois poços, o tomador de decisão possui as seguintes quatro alternativas:

- perfurar apenas o poço S_1 e encerrar o programa;
- perfurar o poço S_1 e, em seguida, realizar a perfuração do poço S_2 ;
- perfurar apenas o poço S_2 e encerrar o programa;
- perfurar o poço S_2 e, em seguida, realizar a perfuração do poço S_1 .

Supondo que o poço S_1 tenha sido perfurado primeiro, com $p(S_1)$ a probabilidade de ser observado um resultado favorável, o valor esperado posterior (estático) é dado por [09]:

$$\mathbb{E}[X | S_1] = \int \sum_{i=1}^n \max_{a_i \in A_i} \{ \mathbb{E}[v(x_i, a_i) | S_1] \} p(S_1) dS_1. \quad (2-35)$$

O cálculo do valor esperado posterior requer a determinação do valor esperado condicional $\mathbb{E}(v(x_i, a_i) | S_1)$, bem como da função densidade de probabilidade marginal $p(S_1)$, a qual pode ser obtida a partir da distribuição a priori $p(X)$ e da verossimilhança $p(S_1 | X)$ por meio do Teorema de Bayes, Equação (2-1).

Nos testes sequenciais, o integrando da solução torna-se mais complexo, pois é necessário considerar todas as possíveis sequências de aquisição de informação. O tomador de decisão somente irá realizar a perfuração do segundo poço se o valor adicional, descontado o custo do segundo poço P_2 , for maior do que o valor do primeiro poço isolado, isto é, temos a seguinte condição:

$$\int_{S_2} \sum_{i=1}^n \max_{a_i \in A_i} \{ \mathbb{E}(v(x_i, a_i) \mid S_1, S_2) \} p(S_2 \mid S_1) dS_2 - P_2 > \sum_{i=1}^n \max_{a_i \in A_i} \{ \mathbb{E}(v(x_i, a_i) \mid S_1) \} . \quad (2-36)$$

O lado esquerdo da Equação (2-36) é denominado *teste continuado*, enquanto o lado direito está associado à decisão do agente em interromper o programa de perfuração após perfurar o primeiro poço. Dessa maneira, o valor esperado posterior à perfuração do primeiro poço, tendo a opção de continuar com a perfuração do segundo poço, torna-se:

$$\mathbb{E}[X \mid S_2, S_1] = \int \max \left\{ \int_{S_2} \sum_{i=1}^n \max_{a_i} \left\{ \mathbb{E}[v(x_i, a_i) \mid S_1, S_2] \right\} p(S_2 \mid S_1) dS_2 - P_2, \right. \\ \left. \sum_{i=1}^n \max_{a_i} \left\{ \mathbb{E}[v(x_i, a_i) \mid S_1] \right\} \right\} p(S_1) dS_1. \quad (2-37)$$

e, sendo o tomador de decisão neutro ao risco, o VOI é definido como a diferença entre os valores a posteriori e a priori, conforme a Equação (2-33). Este VOI deve ser comparado ao custo P_1 do poço S_1 . Se o VOI for maior do que esse custo, torna-se justificável realizar a perfuração sequencial iniciando pelo poço S_1 . O esquema ótimo de perfuração sequencial pode, entretanto, indicar que a melhor estratégia seja iniciar pela perfuração do poço S_2 e, em seguida, executar a perfuração do poço S_1 . Os valores a posteriori de todas as estratégias devem ser avaliados e comparados após a incorporação dos custos das perfurações.

De forma mais geral, para perfurações sequenciais $S_j, j = 1, \dots, m$, o VOI pode ser escrito como uma sequência de integrais e maximizações intercaladas, de forma. As integrais (ou somas, no caso de espaço amostral discreto) são realizadas sobre os resultados observados das perfurações. As maximizações, por sua vez, são realizadas sobre as alternativas de continuar ou interromper o processo de perfuração. A situação pode ser ilustrada por meio de uma árvore de decisão parcialmente desenhada, apresentada na Figura 2.9. Em cada ramo da árvore, o tomador de decisão pode optar por continuar a perfuração ou interromper.

O valor posterior de VOSI iniciando pela perfuração do poço S_{j1} é dado por:




Figura 2.9: Ilustração parcial de uma campanha de perfuração sequencial. Fonte [10].

$$\mathbb{E}[\cdot \mid S_{j1}] = \int \max \left\{ \max_{j2 \neq j1} \{ContVal_{j2}(S_{j1})\}, \sum_{i=1}^n \max_{a_i} \{\mathbb{E}[v(x_i, a_i) \mid S_{j1}]\} \right\} p(S_{j1}) dS_{j1} \quad (2-38)$$

onde o valor de continuação (*ContVal*), no caso de mais perfurações sequenciais, é definido como:

$$ContVal_{j2}(S_{j1}) = \int_{S_{j2}} \max \left\{ \max_{j3 \neq j1, j2} \{ContVal_{j3}(S_{j1}, S_{j2})\}, \sum_{i=1}^n \max_{a_i} \{\mathbb{E}[v(x_i, a_i) \mid S_{j1}, S_{j2}]\} \right\} p(S_{j2} \mid S_{j1}) dS_{j2} - P_{j2}. \quad (2-39)$$

Devido ao encadeamento associado aos valores de continuação, a obtenção computacional do valor a posteriori e do VOI revela-se, em geral, altamente complexa. A solução para a formulação geral é fornecida pela programação dinâmica. Para modelos pequenos e problemas simplificados, essa solução pode ser obtida exatamente. Entretanto, para modelos de maior porte, estratégias heurísticas são necessárias na prática.

Na delimitação de campos de petróleo, os custos de perfuração e aquisição de dados são elevados, mas seu potencial de impacto estratégico também é significativo. A análise do VOSI permite:

- Priorizar locais de perfuração que maximizem o aprendizado geológico, não apenas a produção imediata;
- Reduzir riscos de sobrecapitalização, evitando investimentos antecipados em poços ou plataformas antes da confirmação do potencial econômico;
- Otimizar a sequência de perfuração, de forma que poços de menor custo e maior capacidade de aprendizado sejam executados primeiro, servindo como filtros para decisões futuras;
- Integrar incertezas múltiplas (volume, qualidade do reservatório, custos de operação e preço do petróleo) em uma estrutura unificada de apoio à decisão.

O uso do VOSI fortalece o processo decisório em três dimensões principais. Na dimensão econômica, contribui para a maximização do VPL esperado do campo, ao considerar diferentes caminhos de informação. Na dimensão operacional, permite um planejamento mais eficiente da alocação de recursos de perfuração e aquisição de dados. Por fim, na dimensão estratégica, aumenta a robustez das decisões, possibilitando que as companhias mantenham flexibilidade diante da incerteza e ajustem os planos de desenvolvimento conforme novos dados surgem. Dessa forma, a aplicação do VOSI na delimitação de campos de petróleo não apenas reduz a probabilidade de erros críticos, mas também aumenta a chance de capturar valor em longo prazo, equilibrando risco, custo e aprendizado.

2.1.6

Modelo de Decisão Sequencial

O **Modelo de Decisão Sequencial** (SDM, do inglês *Sequential Decision Model*) é um arcabouço fundamental para problemas em que decisões devem ser tomadas em estágios sucessivos, sob incerteza e com aprendizado ao longo do processo. No contexto da exploração e avaliação de poços de petróleo o SDM permite representar a sequência de escolhas de perfuração, incorporando o fato de que os resultados observados em estágios anteriores influenciam as decisões futuras. A representação gráfica de um SDM pode ser feita de várias maneiras, vamos salientar três principais. Uma forma compacta é ilustrada na Figura 2.10, em que quadrados representam decisões (escolha das possíveis alternativas) e círculos representam os possíveis resultados incertos da alternativa escolhida [11]. O tempo avança da esquerda para a direita, sendo que o aumento do índice indica os estágios de tomada de decisão, também chamados de épocas de decisão. Do estágio de decisão anterior para o próximo,

o resultado incerto da alternativa escolhida é revelado, o que significa que o tomador de decisão adquire aprendizado entre os estágios. Esse aprendizado tem o potencial de alterar o valor esperado das alternativas do estágio seguinte. A mudança no valor esperado das alternativas pode levar a uma escolha diferente em função do conhecimento adquirido previamente.




Figura 2.10: Representação esquemática do SDM. Fonte [11].

Outra forma de representação do SDM é ilustrada na Figura 2.11, onde cada alternativa tem um certo número de resultados e cada resultado é a entrada para a próxima decisão. Esse encadeamento explicita o caráter sequencial e probabilístico do problema, mas também revela sua complexidade combinatória, conhecida como maldição da dimensionalidade (*curse of dimensionality*).




Figura 2.11: Representação esquemática alternativa do SDM. Fonte [12].

O objetivo central do SDM é determinar a **política ótima**, ou seja, a sequência de escolhas que maximiza o valor esperado da campanha de perfuração. Para resolver esse problema, utiliza-se a Programação Dinâmica Estocástica (SDP, do inglês *Stochastic Dynamic Programming*), formalizada originalmente por Bellman em [13]. A solução se baseia na equação de Bellman, que define o valor ótimo em cada nó de decisão como o máximo valor esperado dentre as alternativas possíveis, levando em conta tanto a recompensa imediata quanto o valor futuro associado às escolhas subsequentes. A equação de Bellman é dada matematicamente por [12]:

$$V_i(\omega_i) = \max_{a \in A(i)} \left(\sum_{x \in X(a)} [P(x|\omega_i) (r_a^x + \delta V(\omega_i^{a,x}))] \right), \quad (2-40)$$

onde $V_i(\omega_i)$ é o valor esperado ótimo no nó de decisão i , condicionado ao estado de conhecimento ω_i . Cada alternativa a possui um conjunto de

possíveis resultados $X(a)$, cada um com probabilidade de ocorrência $P(x|\omega_i)$ e recompensa imediata r_a^x . O termo $V(\omega_i^{a,x})$ representa o valor esperado futuro (valor de continuação) quando a sequência de decisão segue o caminho a, x , corrigido pelo fator de desconto $\delta = (1 + r)^{-1}$, sendo r a taxa de desconto. Embora o SDP garanta a solução ótima, sua aplicação direta é limitada a problemas de pequeno porte, devido ao crescimento exponencial do espaço de estados, alternativas e desfechos. Para problemas maiores, heurísticas e métodos aproximativos são necessários, mas o SDM e a equação de Bellman continuam sendo a base conceitual que estrutura a formulação do problema.

A terceira forma de representação gráfica do SDM é a já conhecida árvore de decisão. Esse tipo de representação é mais detalhado e facilita a visualização da mecânica de cada decisão individual, mostrando de forma explícita como alternativas e resultados se encadeiam ao longo dos estágios. No entanto, a complexidade do modelo cresce rapidamente com o número de alternativas disponíveis, o conjunto de possíveis resultados e o número de estágios considerados. A Figura 2.12 mostra um simples SDM com dois estágios (decisões). Cada decisão possui duas alternativas, e cada alternativa se desdobra em dois possíveis resultados. Esse exemplo ilustra de forma compacta como a árvore de decisão explicita o encadeamento das escolhas e incertezas, destacando, ao mesmo tempo, o desafio do crescimento combinatório à medida que o problema se torna mais realista.




Figura 2.12: Árvore de decisão representando um simples SDM. Fonte [11].

Em cada estágio, o número de nós de decisão aumenta, e estes podem ser identificados por $D_{s,j}$, onde s representa o número do estágio e j a posição relativa dentro do estágio. O conjunto de alternativas possíveis em cada nó, denotado por $A(D_{s,j})$, pode variar conforme o contexto da decisão. De forma análoga, cada resultado incerto x pertence ao conjunto de possíveis resultados $X(a)$, que depende da alternativa escolhida a , a qual, por sua vez, está associada ao nó de decisão $D_{s,j}$.

A Equação (2-40) é aplicada recursivamente em todos os nós de decisão, iniciando no último estágio e sendo progressivamente utilizada em direção ao primeiro estágio via processo SDP. A utilização do SDP no modelo de decisão apresentado na Figura 2.12 pode ser exemplificada conforme ilustrado na Figura 2.13.




Figura 2.13: Exemplo do processo SDP. Fonte [11].

A Figura 2.14 mostra um nó de decisão genérico tal como os nós apresentados nas Figuras 2.12 e 2.13. Este nó não está no último estágio, o que significa que novos nós de decisão continuam a partir de cada um dos ramos de resultado.




Figura 2.14: Nó de decisão genérico. Fonte [11].

A principal diferença de um nó de decisão genérico para um nó de decisão genérico no último estágio é que, para obter o valor esperado de cada alternativa, utiliza-se a média ponderada pelas probabilidades de ocorrência, considerando tanto as recompensas imediatas r_a^x quanto o termo adicional $\delta V(\omega_i^{a,x})$, que representa o valor esperado futuro. O estado de conhecimento

posterior $\omega_{i+1} = \omega_i^{a,x}$ é atualizado de acordo com a informação revelada pelo resultado x , quando a alternativa a é escolhida. A Equação (2-40), equação de Bellman, sintetiza o método e permite a aplicação recursiva do processo SDP.

O valor mais importante da política ótima é o valor esperado da campanha antes do início da perfuração. Isso significa que, com base no conhecimento prévio ω_0 , espera-se obter $V_0(\omega_0)$ a partir da sequência ótima de perfuração, aproveitando a informação geológica espacial disponível antes de cada decisão. Todas as probabilidades e valores esperados $V_i(\omega_i)$, calculados ao longo do processo da programação dinâmica, são armazenados juntamente com as regras de decisão e são considerados parte integrante da política ótima. [14] apresenta uma política ótima contendo todas essas informações em um caso hipotético com três poços candidatos (A, B, C), cada um com quatro possíveis resultados categóricos ($\#0, \#1, \#2, \#3$), associados à função de valor $r = [-10, -5, 5, 10]$, conforme ilustrado na Figura 2.15.




Figura 2.15: Análise simples da política ótima para três poços. Fonte [11].

É importante observar que, em algumas situações, a sequência de perfuração pode ser interrompida precocemente devido aos resultados observados. Além disso, algumas sequências de perfuração podem se repetir para diferentes combinações de resultados. Uma alternativa para representar a política ótima é listá-la em termos de eventos conjuntos associados a probabilidades conjuntas, como mostrado no lado direito da Figura 2.15.

Existe, portanto, um grande potencial em extrair percepções decisórias e agregar valor aplicando o processamento heurístico dos métodos à política ótima, especialmente em modelos de grande porte, nos quais a representação gráfica direta da política ótima torna-se inviável.

2.2

Valor da Flexibilidade

A flexibilidade em projetos de exploração e produção (E&P) pode ser entendida como a capacidade de ajustar decisões à medida que novas informações surgem ou que incertezas se resolvem ao longo do tempo. Esse conceito está intimamente ligado à teoria das Opções Reais, na qual o gestor preserva o direito — mas não a obrigação — de modificar o curso de ação de acordo com as condições futuras. Assim, o Valor da Flexibilidade (VoF) corresponde ao benefício econômico de manter abertas alternativas de decisão diante da incerteza.




Figura 2.16: Valor da flexibilidade. Fonte [11].

2.3

Incertezas Técnicas

A hematita é o mineral de ferro mais importante devido a sua alta ocorrência em vários tipos de rochas e suas origens diversas. A composição química deste mineral é Fe_2O_3 , com uma fração mássica em ferro de 69,9% e uma fração mássica em oxigênio de




Figura 2.17: 3D Egg model

2.4

Incertezas do Mercado

A hematita é o mineral de ferro mais importante devido a sua alta ocorrência em vários tipos de rochas e suas origens diversas. A composição química deste mineral é Fe_2O_3 , com uma fração mássica em ferro de 69,9% e uma fração mássica em oxigênio de

2.5

Redes Neurais

A hematita é o mineral de ferro mais importante devido a sua alta ocorrência em vários tipos de rochas e suas origens diversas. A composição química deste mineral é Fe_2O_3 , com uma fração mássica em ferro de 69,9% e uma fração mássica em oxigênio de

2.6

Redes Neurais Convolucionais

A hematita é o mineral de ferro mais importante devido a sua alta ocorrência em vários tipos de rochas e suas origens diversas. A composição química deste mineral é Fe_2O_3 , com uma fração mássica em ferro de 69,9% e uma fração mássica em oxigênio

3

Estado da Arte

Year	0	1	2	3	4	5	6	7	8	9	10
Production Level		9.0	7.7	6.5	5.5	4.7	4.0	3.4	2.9	2.5	2.1
Variable Op Cost Rate	10.0	10.2	10.4	10.6	10.8	11.0	11.3	11.5	11.7	12.0	12.2
Oil Price	25.0	25.0	25.0	25.0	25.0	25.0	25.0	25.0	25.0	25.0	25.0
Revenues		225.0	191.3	162.6	138.2	117.5	99.8	84.9	72.1	61.3	52.1
Production Cost		(96.8)	(84.6)	(74.0)	(64.8)	(56.9)	(50.0)	(44.0)	(38.8)	(34.3)	(30.4)
Cash Flow		128.2	106.7	88.6	73.4	60.6	49.9	40.9	33.3	27.0	21.7
Profit Sharing		(32.1)	(26.7)	(22.1)	(18.3)	(15.1)	(12.5)	(10.2)	(8.3)	(6.8)	(5.4)
Net Cash Flows		96.2	80.0	66.4	55.0	45.4	37.4	30.7	25.0	20.3	16.3
PV of Cash Flows	392.0	411.6	331.2	263.8	207.3	159.9	120.6	86.9	59.0	35.8	16.3
Cash Flow Ratios		0.233	0.241	0.251	0.265	0.284	0.311	0.352	0.423	0.566	1.000

Tabela 3.1: A Risk-Neutral Version of BDH's Base Case Analysis

Year	0	1	2	3	4	5	6	7	8	9	10
Production Level		9.0	7.7	6.5	5.5	4.7	4.0	3.4	2.9	2.5	2.1
Variable Op Cost Rate	10.0	10.2	10.4	10.6	10.8	11.0	11.3	11.5	11.7	12.0	12.2
Oil Price	25.0	25.0	25.0	25.0	25.0	25.0	25.0	25.0	25.0	25.0	25.0
Revenues		225.0	191.3	162.6	138.2	117.5	99.8	84.9	72.1	61.3	52.1
Production Cost		(96.8)	(84.6)	(74.0)	(64.8)	(56.9)	(50.0)	(44.0)	(38.8)	(34.3)	(30.4)
Cash Flow		128.2	106.7	88.6	73.4	60.6	49.9	40.9	33.3	27.0	21.7
Profit Sharing		(32.1)	(26.7)	(22.1)	(18.3)	(15.1)	(12.5)	(10.2)	(8.3)	(6.8)	(5.4)
Net Cash Flows		96.2	80.0	66.4	55.0	45.4	37.4	30.7	25.0	20.3	16.3
PV of Cash Flows	392.0	411.6	331.2	263.8	207.3	159.9	120.6	86.9	59.0	35.8	16.3
Cash Flow Ratios		0.233	0.241	0.251	0.265	0.284	0.311	0.352	0.423	0.566	1.000

4

Resultados Preliminares




Figura 4.1: Arquitetura da Rede

5

Próximos Passos

Projetos de Exploração e Produção (E&P) envolvem elevada incerteza geológica e de mercado. Métodos tradicionais de avaliação, como o Fluxo de Caixa Descontado, não capturam o valor da flexibilidade gerencial. Nesse contexto, o **Valor da Informação** (VoI) quantifica os benefícios de reduzir incertezas, enquanto as **Opções Reais** (ROA) avaliam a flexibilidade de adiar, expandir ou abandonar projetos.

6

Conclusão

Um sistema de microscopia digital com reconhecimento e classificação automática dos cristais de hematita em minérios de ferro foi desenvolvido.

O método utiliza operações tradicionais de processamento digital de imagens e propõe uma segmentação automática de cristais baseada no cálculo da distância espectral, a fim de controlar ...

É fundamental também comentar que ...

Assim, como uma proposta para trabalho futuro, pode-se buscar combinar os dois enfoques...

Referências Bibliográficas

- [01] BRATVOLD, R. B.; BEGG, S. H. **Making Good Decisions**. Society of Petroleum Engineers, Richardson, TX, 1st edition, 2010.
- [02] HOWARD, R. A. **Speaking of decisions: Precise decision language**. *Decision Analysis*, 2:71–78, 2004.
- [03] BRATVOLD, R. B.; BICKEL, J. E.; LOHNE, H. P. **Value of information in the oil and gas industry: Past, present, and future**. *SPE Res Eval & Eng*, 12:630–638, 2009.
- [04] BICKEL, J. E. **The relationship between perfect and imperfect information in a two-action risk-sensitive problem**. *Decision Analysis*, 5:116–128, 2008.
- [05] PRATT, J. W.; RAIFFA, H.; SCHLAIFER, R. **Introduction to Statistical Decision Theory**. The MIT Press, Cambridge, MA, 1st edition, 1995.
- [06] DIAS, M. A. G. **Opções Reais Híbridas com Aplicações em Petróleo**. Tese de doutorado, PUC-Rio, Rio de Janeiro, 2005.
- [07] PINTO, J. R.; AGUIAR, J. C.; MORAIS, F. S. **The value of information from time-lapse seismic data**. *The Leading Edge*, 5:572–576, 2011.
- [08] LOPES, Y. G.; ALMEIDA, A. T. **Assessment of synergies for selecting a project portfolio in the petroleum industry based on a multi-attribute utility function**. *Journal of Petroleum Science and Engineering*, 126:131–140, 2015.
- [09] EIDSVIK, J.; MUKERJI, T.; BHATTACHARJYA, D. **Value of Information in the Earth Sciences**. Cambridge University Press, Cambridge, UK, 1st edition, 2015.
- [10] BICKEL, J. E.; SMITH, J. E. **Optimal sequential exploration: A binary learning model**. *Decision Analysis*, 3:16–32, 2006.
- [11] MOROSOV, A. L. **Sequential drilling decisions based on explicit joint probability distribution of spatially distributed subsurface data**. Phd thesis, University of Stavanger, Stavanger, Norway, 2024.

- [12] MOROSOV, A. L.; BRATVOLD, R. B. **Appraisal campaign selection based on the maximum value of sequential information.** Journal of Petroleum Science and Engineering, 208:1–13, 2022.
- [13] BELMAN, R. E. **Dynamic Programming.** Princeton University Press, Princeton, NJ, 1957.
- [14] MOROSOV, A. L.; BRATVOLD, R. B. **Drilling-campaign optimization using sequential information and policy analytics.** SPE Journal, 26:3609–3625, 2021.
- [15] BRATVOLD, R. B.; THOMAS, P. **Robust discretization of continuous probability distributions for value-of-information analysis.** In: INTERNATIONAL PETROLEUM TECHNOLOGY CONFERENCE, p. 1–22, Kuala Lumpur, Malaysia, 2008.

A

Trabalhos Publicados

The following paper was published ...