



Wellington Carlos da Rosa Nascimento

**Valor da Informação e Machine Learning na
Avaliação Econômica de Projetos de E&P**

Proposta de Tese de Doutorado

Proposta de Tese apresentada como requisito parcial para obtenção do título de Doutor pelo Programa de Pós-graduação em Engenharia Elétrica, do Departamento de Engenharia Elétrica da PUC-Rio.

Orientador : Prof. Marco Aurélio C. Pacheco

Coorientador: Prof. Marco Antonio G. Dias

Resumo

Nascimento, Wellington Carlos da Rosa; Pacheco, Marco Aurélio C.; Dias, Marco Antonio G.. **Valor da Informação e Machine Learning na Avaliação Econômica de Projetos de E&P**. Rio de Janeiro, 2025. 76p. Proposta de Tese de Doutorado – Departamento de Engenharia Elétrica, Pontifícia Universidade Católica do Rio de Janeiro.

Projetos de Exploração e Produção (E&P) envolvem elevada incerteza geológica e de mercado. Métodos tradicionais de avaliação, como o Fluxo de Caixa Descontado, não capturam o valor da flexibilidade gerencial. Nesse contexto, o **Valor da Informação** (VoI) quantifica os benefícios de reduzir incertezas, enquanto as **Opções Reais** (ROA) avaliam a flexibilidade de adiar, expandir ou abandonar projetos. O **Aprendizado de Máquina** (ML) complementa essas abordagens ao reduzir custos computacionais com modelos proxy, apoiar a análise de VoI identificando informações críticas e aproximar soluções de ROA por meio de algoritmos de regressão e reforço. Assim, a integração de ML, VoI e ROA permite decisões mais robustas, aumentando o valor econômico e reduzindo riscos em projetos de E&P.

Sumário

1	Introdução	9
1.1	Objetivos	11
1.2	Publicações	11
1.3	Organização da Proposta	12
2	Fundamentação Teórica	13
2.1	Valor da Informação	14
2.1.1	Quantificando a Informação	14
2.1.2	Etapas no Cálculo do VOI	16
2.1.3	VOI e o Problema TALL-N	20
2.1.4	Medida de Aprendizagem η^2	23
2.1.5	Valor da Informação Sequencial	29
2.1.6	Modelo de Decisão Sequencial	34
2.2	Valor da Flexibilidade	40
2.3	Incertezas Técnicas	43
2.4	Incertezas do Mercado	49
2.4.1	Modelagem do Custo Operacional	50
2.4.2	Modelagem do Preço do Petróleo	51
2.4.3	Least Squares Monte Carlo	55
3	Aplicação de MLP e CNN na E&P	59
3.1	Redes Neurais Artificiais	60
3.2	Redes Neurais Convolucionais	67
4	Estado da arte	69
5	Resultados preliminares	70
6	Próximos Passos	71
7	Conclusão	72
	Referências Bibliográficas	73

Lista de figuras

Figura 2.1	Árvore de decisão genérica do VoI. Fonte: [01].	17
Figura 2.2	Inversão da árvore de decisão. Fonte: [01].	18
Figura 2.3	Problema TALL-N com preferência inicial de risco. Fonte: [04].	21
Figura 2.4	Máximo valor de RVOI em função de $c = \frac{\mu-v}{\sigma}$.	23
Figura 2.5	Valor de RVOI em função de $c = \frac{\mu-v}{\sigma}$.	24
Figura 2.6	VOI em função de η^2 .	25
Figura 2.7	Valor empírico e teórico de $\eta^2(X S)$ para diferentes níveis de correlação ρ .	28
Figura 2.8	Decomposição da variância total em função da correlação ρ .	28
Figura 2.9	Ilustração parcial de uma campanha de perfuração sequencial. Fonte [10].	32
Figura 2.10	Representação esquemática do SDM. Fonte [11].	34
Figura 2.11	Representação esquemática alternativa do SDM. Fonte [12].	35
Figura 2.12	Árvore de decisão representando um simples SDM. Fonte [11].	36
Figura 2.13	Exemplo do processo SDP. Fonte [11].	37
Figura 2.14	Nó de decisão genérico. Fonte [11].	37
Figura 2.15	Análise simples da política ótima para três poços. Fonte [11].	39
Figura 2.16	Divisão de decisões para aprender antes de avançar. Fonte [01].	40
Figura 2.17	Valor da flexibilidade: a) curva de produção, b) Redução da produção em períodos de preço baixo, c) Produção reduzida (acelerada) com preço baixo (alto), d) Uma previsão de preço com reversão à média, e) Valor do projeto com a magnitude da incerteza, f) Valor esperado do projeto em função da incerteza no preço. Fonte [11].	42
Figura 2.18	Modelo Egg 3D: distribuição de permeabilidade.	45
Figura 2.19	Mapas de permeabilidade da camada superior para 25 realizações.	47
Figura 2.20	Taxas de produção de óleo e água para os quatro poços produtores.	49
Figura 2.21	Evolução dos custos operacionais ao longo de 10 anos.	51
Figura 2.22	Calibração do modelo de SS para os preços do petróleo.	54
Figura 2.23	Simulações do preços do petróleo, intervalos de confiança e exemplos de trajetórias.	55
Figura 3.1	Modelo do neurônio biológico. Fonte [32].	61
Figura 3.2	Modelo do neurônio artificial. Fonte [30].	62
Figura 3.3	Funções de ativação: (a) Degrau, (b) Sigmoide, (c) ReLU e (d) Softmax.	64

Figura 3.4	Arquitetura de uma MLP com duas camadas ocultas.	
	Fonte [30].	65
Figura 3.5	Direção dos fluxos de sinais em uma MLP. Fonte [30].	66

Lista de tabelas

Tabela 2.1	Propriedades gerais do modelo Egg.	46
Tabela 2.2	Propriedades do reservatório/fluidos para o modelo Egg.	48
Tabela 2.3	Parâmetros calibrados para o modelo de SS.	54

Lista de Abreviaturas

E&P – *Exploração e Produção*

VOI – *Value of Information*

VoF – *Value of Flexibility*

VPL – Valor Presente Líquido

NPV – *Net Present Value*

VOPI – *Value of Perfect Information*

EVPI – *Expected Value of Perfect Information*

EVII – *Expected Value of Imperfect Information*

TALL-N – *Two-Action Linear-Loss with Normal priors*

RVOI – *Relative Value of Information*

VOSI – *Value of Sequential Information*

SDM – *Sequential Decision Model*

SDP – *Stochastic Dynamic Programming*

MGB – Movimento Geométrico Browniano

LSM – *Least Squares Monte Carlo*

ANN – *Artificial Neural Networks*

AI – *Artificial Intelligence*

ML – *Machine Learning*

DL – *Deep Learning*

RL – *Reinforcement Learning*

MLP – *Multilayer Perceptron*

DNN – *Deep Neural Network*

GPU – *Graphics Processing Unit*

CNN – *Convolutional Neural Network*

Lista de Algoritmos

1 Algoritmo *Backpropagation* 66

1

Introdução

O desenvolvimento de projetos de produção de petróleo e gás natural requer o planejamento estruturado de diversas etapas ao longo do ciclo de vida do campo, abrangendo exploração, avaliação, desenvolvimento, operação e abandono. Na fase exploratória, o principal objetivo é identificar acumulações potenciais de hidrocarbonetos por meio de levantamentos geofísicos, como sísmica, gravimetria e análises geológicas. Caso sejam encontrados indícios de petróleo e gás, inicia-se a fase de avaliação, destinada a determinar a viabilidade técnica e econômica da produção. Uma vez comprovado o potencial do reservatório, passa-se à fase de desenvolvimento, na qual são elaborados planos para instalação de plataformas, perfuração e completação de poços, buscando maximizar a recuperação de hidrocarbonetos com o menor custo possível.

Campanhas de perfuração otimamente planejadas são fundamentais para aumentar a recuperação de óleo e gerar valor ao projeto. Elas ocorrem em diferentes estágios do ciclo de vida do campo, desde a exploração até o desenvolvimento e perfuração complementar. Uma parcela significativa do risco econômico está associada à incerteza geológica, razão pela qual as equipes de subsuperfície são frequentemente responsáveis por otimizar parâmetros da campanha de perfuração, como o número de poços, suas localizações e a sequência de perfuração.

As empresas de petróleo utilizam as informações obtidas dos poços perfurados para ajustar as etapas subsequentes da campanha, incorporando o aprendizado adquirido. No entanto, métodos clássicos de otimização geralmente não consideram explicitamente esse processo de aprendizado sequencial e flexibilidade temporal. Assim, considerar a aquisição sequencial de informações geológicas e a tomada de decisão adaptativa durante as campanhas de perfuração pode agregar valor significativo ao projeto, mesmo sob condições de incerteza na caracterização geológica e nos parâmetros econômicos advindos do mercado e que influenciam diretamente o valor do projeto. O desempenho insatisfatório de muitos empreendimentos petrolíferos decorre da baixa aplicação de recursos na tomada de decisão e da ausência de investimentos adequados para estimar o retorno esperado do projeto, o que resulta na superestimação dos ganhos ou

na subestimação das perdas.

Na literatura há consenso que três tipos de riscos devem ser considerados: perda de oportunidade (quando um prospecto é incorretamente considerado inviável), desenvolvimento não comercial (quando um campo é desenvolvido mesmo sendo antieconômico) e desenvolvimento subótimo (quando o campo é desenvolvido com retorno inferior ao máximo possível). A mitigação desses riscos depende da obtenção de informações adicionais que reduzam as incertezas relevantes. Uma metodologia consolidada para avaliar a aquisição de informação é a Análise de Valor da Informação, que relaciona a incerteza do reservatório às consequências econômicas potenciais. Embora o conceito seja amplamente difundido, sua aplicação prática torna-se complexa quando há múltiplos atributos incertos e informações incompletas ou pouco confiáveis. A integração entre Valor da Informação, Teoria de Opções Reais e modelos estocásticos de preços constitui uma abordagem robusta para apoiar decisões sob incerteza no setor de Exploração e Produção. A Teoria de Opções Reais incorpora o valor da flexibilidade gerencial, como adiar, expandir, suspender ou abandonar projetos conforme novas informações são obtidas e a favorabilidade do mercado. Entre os métodos numéricos, o Least Squares Monte Carlo destaca-se por permitir a estimação do valor ótimo de decisões sequenciais, considerando múltiplas fontes de incerteza e caminhos simulados de preços e custos. As incertezas de mercado podem ser representadas por modelos estocásticos como o Movimento Geométrico Browniano ou pelo modelo de dois fatores de Schwartz e Smith, que decompõe o logaritmo do preço do petróleo em dois componentes: um de longo prazo (nível de equilíbrio) e outro de curto prazo (desvio transitório). Essa formulação captura tanto a reversão à média quanto a volatilidade transitória, permitindo análises econômicas mais realistas e robustas.

Nos últimos anos, no entanto, a transformação digital e o avanço da Inteligência Artificial vêm modificando profundamente o processo decisório na indústria de petróleo e gás. Essa transformação, frequentemente associada à chamada quarta revolução industrial, é impulsionada pela convergência entre tecnologias físicas e digitais, como Aprendizado de Máquina, robótica e sistemas autônomos. O Aprendizado de Máquina tem demonstrado grande potencial em aplicações de engenharia de reservatórios, permitindo aprimorar a análise de grandes volumes de dados e identificar padrões complexos. Em particular, o Aprendizado Profundo, por meio de redes neurais artificiais e redes neurais convolucionais, vem sendo amplamente utilizado para modelar relações não lineares entre as propriedades petrofísicas do reservatório e desempenho na produção dos poços. Tais técnicas têm se mostrado eficazes para estimar

a produtividade de poços, permeabilidade efetiva e posicionamento ótimo sob incerteza geológica. Estudos recentes demonstram a integração de redes neurais convolucionais com esquemas de otimização robusta, cujo objetivo é determinar a melhor localização de poços produtores em reservatórios sob incerteza. Nessas aplicações, as redes neurais convolucionais são treinadas para correlacionar propriedades petrofísicas espaciais com a produção acumulada de hidrocarbonetos, fornecendo estimativas de produtividade em diferentes realizações equiprováveis.

Com base nesses avanços, esta proposta de tese propõe a utilização de Aprendizado de Máquina para estimar o Valor da Informação Sequencial e apoiar a delimitação de campos de petróleo tendo como parâmetro de decisão uma medida de redução da incerteza. Embora o uso de Aprendizado de Máquina na fase de desenvolvimento seja uma realidade, sua aplicação na etapa de delimitação ainda é recente e promissora. A integração de métodos de Inteligência Artificial com a análise econômica de projetos exploratórios representa uma nova fronteira de pesquisa, permitindo quantificar de forma mais precisa o impacto do aprendizado geológico e econômico sobre o valor total do projeto.

A motivação para o desenvolvimento desse trabalho ...

Os resultados preliminares são apresentados no capítulo ...

A principal contribuição desse trabalho é ...

1.1

Objetivos

Os objetivos desse trabalho são:

- Desenvolver um novo método para estimar a locação de poços exploratórios na fase de delimitação com incertezas geológicas utilizando Valor da Informação e Medida de Aprendizagem;
- Desenvolver modelos de Deep Learning via Redes Neurais Convolucionais que levem em consideração o novo método e as incertezas geológicas;
- Aplicar o método desenvolvido em modelos de reservatórios com características similares aos reservatórios reais.

1.2

Publicações

No início do doutorado o aluno apresentou o trabalho **Pareto optimization via genetic algorithm for selecting a portfolio of oil and gas exploration projects** no *2023 International Conference on Algorithms, Computing and Data Processing* e no *18th International Congress of the Brazilian*

Geophysical Society & Expogef. O trabalho foi resultado da disciplina Computação Evolucionária ministrada pela Profa. Manoela Kohler e Prof. Marco Aurélio: <https://ieeexplore.ieee.org/document/10483593>.

Um estudo orientado realizado com os professores Marco Antonio Dias e Marco Aurélio resultou no trabalho **Learning, Uncertainty Reduction and Optimizing the Location of Delimitation Wells in Hydrocarbon E&P** que foi apresentado na *27th Annual International Real Options Conference* em Bologna/Italy: https://realoptions.org/programAbstracts2024/_proceedings.html.

O aluno também participou do Programa de Doutorado Sanduíche no Exterior (PDSE/CAPES), na Universidade de Stavanger na Noruega, sob a supervisão do Prof. Reidar Bratvold, uma referência mundial em Métodos de Apoio à Decisão com aplicações na indústria de petróleo. O produto desse estágio foi um artigo científico que atualmente está em fase final de ajuste para submissão. Esse mesmo trabalho será apresentado na *Brazilian Geophysical Society Conference - Rio'25* com o título **Real Options Approach for Economic Evaluation of Oil and Gas E&P Projects Under Geological and Market Uncertainties**: <https://rio25.sbgf.org.br/Pages/technicalProgram.php#start>.

1.3

Organização da Proposta

No capítulo 2 é apresentado a fundamentação teórica para o entendimento do trabalho desenvolvido. No capítulo 3 é apresentado a nova técnica para lidar com amostras ruidosas RDS, assim como os modelos RDS-C e RDS-J. No capítulo 4 é apresentado o novo modelo RDS-Contrastive. No capítulo 5 é apresentado os detalhes experimentais para avaliação dos modelos. Também é apresentado os resultados dos modelos nos experimentos propostos, além disso é realizado uma análise nas vantagens e desvantagens de cada modelo. Ao final do capítulo 5 é apresentado o Estudo de Caso em detalhes e os resultados preliminares obtidos. No capítulo 6 é apresentado a conclusão e os próximos passos a serem realizados para conclusão desta tese.

2

Fundamentação Teórica

Nesse capítulo será apresentado os fundamentos teóricos necessários para a compreensão desta proposta de tese. Iniciando com os conceitos básicos de Valor da Informação, seguido por sua quantificação, a importância do Valor da Informação Sequencial, bem como sua relação com a Medida de Aprendizagem. Em seguida apresentamos o Valor da Flexibilidade e as técnicas utilizadas para quantificar as incertezas técnicas e de mercado. Por fim definimos o que é Least Squares Monte Carlo e sua importância na valoração dos projetos e como as incertezas influenciam na tomada de decisão.

Sabe-se que o baixo desempenho de algumas empresas de petróleo decorre do reduzido investimento em ferramentas de suporte à decisão e da falta de recursos adequados para estimar com precisão o retorno dos projetos, o que pode resultar tanto na superestimação dos ganhos quanto na subestimação das perdas. Desta maneira, os riscos inerentes ao processo podem passar despercebidos. Três tipos de riscos no desenvolvimento de campos de petróleo devem ser considerados no processo de tomada de decisão:

1. **perda de oportunidade:** um prospecto é considerado não econômico e abandonado, quando na verdade seria viável economicamente;
2. **desenvolvimento não econômico:** um campo inviável é desenvolvido por ter sido erroneamente considerado econômico;
3. **desenvolvimento subótimo:** um campo é desenvolvido, mas gera retorno inferior ao máximo possível, que poderia ser obtido se o modelo de reservatório correto tivesse sido considerado.

O risco envolvido na fase de desenvolvimento pode ser reduzido se informações adicionais forem obtidas para diminuir ou até eliminar uma determinada incerteza. Entretanto, a aquisição de informação está diretamente associada a custos. Por isso, antes de decidir pela obtenção de informação, é sugerido analisar dois aspectos: se vale a pena adquirir informação adicional e se tal informação é de fato capaz de melhorar o processo decisório. Uma ferramenta consistente que pode ser utilizada como critério no processo de decisão é o Valor da Informação, que combina incertezas do reservatório com suas potenciais consequências econômicas.

2.1

Valor da Informação

A prática profissional em engenharia de petróleo e geociências está fortemente associada à aquisição de informações, obtidas sob diversas formas e em múltiplos contextos. O termo informação é usado aqui em um sentido amplo, incluindo coleta de dados, realização de estudos técnicos, contratação de consultores, execução de testes diagnósticos, etc. A expectativa é que a redução da incerteza aumente a chance de que as decisões resultem no desfecho desejado. Sendo assim, a única outra razão válida para coletar informação ou realizar análises técnicas é o cumprimento de exigências pelos órgãos reguladores.

A questão fundamental em qualquer processo de coleta de informação é se a redução esperada da incerteza compensa o custo de se obter a informação. A técnica de *Value of Information* (VOI), em português **Valor da Informação**, é projetada justamente para responder a essa questão [01].

2.1.1

Quantificando a Informação

O objetivo do VOI é estimar o valor de um exercício proposto de coleta de informações, de modo que a decisão de implementá-lo ou não seja feita em bases econômicas. Para que a informação seja valiosa, deve existir uma dependência probabilística entre a informação e os resultados do evento incerto de interesse (relevância). Além disso, o evento de interesse deve impactar suficientemente uma métrica de decisão a ponto de podermos alterar nossa decisão (materialidade). Finalmente, seu valor deve exceder o seu custo, caso em que a regra implícita de investimento recomenda adquirir a informação (valor maior que o custo). O custo de aquisição da informação depende da natureza da informação. O cálculo dos custos inclui salários da equipe, custos de oportunidade e custos diretos óbvios.

O VOI pode ser entendido como o valor atribuído às probabilidades atualizadas. Para calcular esse valor, são necessárias as seguintes informações:

- i) **Probabilidade atuais**, ou *a priori*, dos possíveis resultados que a variável pode assumir (por exemplo, 30% de chance do fator de recuperação ser baixo e 70% de chance de ser alto).
- ii) **Estimativas de confiabilidade (verossimilhança)** da eficácia da informação em prever os resultados (por exemplo, quando o fator de recuperação é conhecido como “alto”, estudos de simulação de reservatórios 3D indicam corretamente “alto” em 80% dos casos).

- iii) **Valores de projeto em termos monetários** para cada uma das possíveis combinações de resultados (por exemplo, VPL de +600 milhões de USD se o fator de recuperação for alto e -100 milhões de USD se for baixo).

Embora os valores do projeto possam ser derivados por meio de análise determinística, recomenda-se o uso do Valor Presente Líquido (VPL, do inglês *Net Present Value – NPV*) esperado, obtido via simulação de Monte Carlo de outras incertezas, devido às complexas inter-relações envolvidas. O cálculo do VOI costuma ser representado em árvores de decisão, pois elas trazem clareza ao processo. O procedimento envolve comparar duas árvores de decisão:

- A primeira árvore representa o valor esperado do projeto com as probabilidades *a priori*.
- A segunda árvore representa o valor esperado do projeto com as probabilidades atualizadas, resultantes da aquisição da informação.

A diferença entre os dois valores fornece o **VOI esperado**. Utilizamos o termo **esperado** em seu sentido matemático restrito, ou seja, o valor obtido ao aplicar repetidamente a metodologia do VOI em diversas decisões. Antes de detalhar o procedimento de cálculo, consideremos primeiro alguns limites intuitivos do VOI:

- Limite inferior: se a informação não altera a decisão, seu valor esperado é zero, independentemente do custo.
- Limite superior: a informação perfeita fornece o valor máximo possível, denominado **Valor Esperado da Informação Perfeita** (EVPI). Este limite superior serve como referência: nenhum processo de aquisição de informação pode exceder o EVPI.

O cálculo do EVPI não depende da existência de métodos perfeitos de aquisição de informação, mas sim de fornecer um *benchmark* para avaliar qualquer processo de coleta de informação. Se o custo do processo excede o EVPI, não há motivo para prosseguir com a proposta. Se o EVPI indicar que vale a pena avançar, procede-se ao cálculo do **Valor Esperado da Informação Imperfeita** (EVII), que leva em conta a confiabilidade da informação obtida.

2.1.2

Etapas no Cálculo do VOI

Os principais procedimentos para conduzir um estudo de VOI são descritos a seguir. Posteriormente, estes passos serão ilustrados por meio de uma decisão simplificada.

1. Calcular o valor esperado da decisão a ser tomada no estado atual (isto é, sem a informação). Este cálculo é denominado **valor do projeto base**.
2. Formular a estrutura da situação de decisão de modo a incluir a nova informação. Isso é feito adicionando um novo ramo ao primeiro nó da árvore de decisão para representar a escolha de adquirir informação. Este ramo leva a um nó de incerteza, cujo evento incerto corresponde aos resultados do exercício de coleta de informação.
3. Calcular o valor da informação perfeita. Se o EVPI for insignificante ou menor que o custo de aquisição da informação, não se deve coletar a informação e deve-se escolher a alternativa de maior valor no projeto base. Caso contrário, prosseguir para o Passo 4.
4. Calcular o valor do projeto com a informação real, ou imperfeita. Este passo é subdividido em:
 - (a) Estimar as probabilidades de verossimilhança, isto é, $P(\text{informação diz} \mid \text{mundo real})$.
 - (b) Calcular as probabilidades atualizadas (posteriores) pelo Teorema de Bayes.
 - (c) Inserir as probabilidades atualizadas na árvore de decisão e resolver para obter o valor do projeto.
5. Calcular o EVII, obtido pela diferença entre os valores dos Passos 4 e 1. Comparar essa diferença com o custo de aquisição da informação.
6. Realizar uma análise de sensibilidade para verificar a robustez da decisão diante de variações nas probabilidades e nos *payoffs*.

A parte mais complexa do procedimento anterior é o Passo 2 — garantir que a formulação da situação de decisão inclua a informação antecipada. Para ilustrar, seja o seguinte exemplo simplificado. Suponha uma decisão binária: realizar uma ação (por exemplo, perfurar um poço) ou não. Denotamos essas alternativas como D_1 e D_2 , ver Figura 2.1.




Figura 2.1: Árvore de decisão genérica do VoI. Fonte: [01].

Há um evento incerto B com dois possíveis resultados: B_1 e B_2 (por exemplo, o poço é comercial ou não). As probabilidades desses resultados são $P(B_1)$ e $P(B_2)$. Se escolhermos D_1 , o valor do projeto é $NPV(B_1)$ ou $NPV(B_2)$, dependendo do resultado. Se escolhermos D_2 , assumimos payoff igual a USD 0. Esse caso constitui o projeto base (Passo 1). Para incluir a opção de coletar informação adicional, adicionamos uma terceira alternativa D_A ao nó inicial da árvore de decisão, indicando a decisão de adquirir informação, A . Os possíveis resultados dessa informação, A_1 ou A_2 , são conhecidos por serem dependentes dos resultados de interesse, B_1 e B_2 . Um exemplo seria um levantamento sísmico 3D, cujos resultados podem ser “Bright Spot” (A_1) ou “No Bright Spot” (A_2). Nesse ponto, não conhecemos as probabilidades de A_1 ou A_2 , mas uma vez conhecidas, retomamos a decisão original. O problema de decisão é então modelado replicando a árvore do projeto base em cada ramo correspondente a A_1 e A_2 . As probabilidades de B , por estarem relacionadas às probabilidades de A , são indicadas como probabilidades condicionais. Por exemplo, se o levantamento sísmico (A_1) indicar “Bright Spot” e decidirmos executar o projeto D_1 , o poço poderá ser comercial com probabilidade $P(\text{Comercial} \mid A_1)$ ou não comercial com probabilidade $P(\text{Não Comercial} \mid A_1)$. Dessa forma, a situação de decisão passa a incluir a opção de coletar informação. O próximo passo é calcular as probabilidades necessárias e resolver a árvore normalmente. Supondo que tenhamos dados de confiabilidade sobre a eficácia de “Bright Spots” na previsão de poços comerciais, podemos combiná-los com as probabilidades a priori por

meio do processo de *tree-flipping* (inversão da árvore de decisão) que permite combinar probabilidades a priori com informações de confiabilidade, conforme ilustrado na Figura 2.2.




Figura 2.2: Inversão da árvore de decisão. Fonte: [01].

A soma das probabilidades dos possíveis resultados da aquisição de informação, $P(A_1)$ e $P(A_2)$, corresponde à probabilidade total. Esse é justamente o denominador do **Teorema de Bayes**, que pode ser escrito de forma geral como:

$$P(B_i | A) = \frac{P(A | B_i) P(B_i)}{\sum_{j=1}^n P(A | B_j) P(B_j)}. \quad (2-1)$$

No caso específico do exemplo acima, obtemos as seguintes probabilidades atualizadas:

$$P(B_1 | A_1) = \frac{P(A_1 | B_1) P(B_1)}{P(A_1 | B_1) P(B_1) + P(A_1 | B_2) P(B_2)} \quad (2-2)$$

$$P(B_2 | A_1) = \frac{P(A_1 | B_2) P(B_2)}{P(A_1 | B_1) P(B_1) + P(A_1 | B_2) P(B_2)} \quad (2-3)$$

$$P(B_1 | A_2) = \frac{P(A_2 | B_1) P(B_1)}{P(A_2 | B_1) P(B_1) + P(A_2 | B_2) P(B_2)} \quad (2-4)$$

$$P(B_2 | A_2) = \frac{P(A_2 | B_2) P(B_2)}{P(A_2 | B_1) P(B_1) + P(A_2 | B_2) P(B_2)} \quad (2-5)$$

Uma questão central na análise de VOI é a origem das probabilidades a priori e de verossimilhança. Em geral, tais probabilidades derivam de avaliações subjetivas, baseadas no conhecimento dos especialistas sobre a situação ou

dados disponíveis. A subjetividade é inerente à análise de decisão: os modelos são aproximações da realidade e frequentemente dependem de julgamentos sem dados empíricos diretos.

Priors: As distribuições a priori descrevem o estado de conhecimento sobre o evento incerto antes da obtenção de novas informações. Essa interpretação como "grau de crença" é amplamente aceita e permite o uso de qualquer fonte de conhecimento ou experiência relevante. Ser capaz de avaliar corretamente distribuições a priori é uma habilidade essencial para engenheiros e geocientistas.

Likelihood: A função de verossimilhança representa a probabilidade condicional da informação observada, dado o evento de interesse. Na prática, pode estar relacionada à qualidade ou à confiabilidade da informação adquirida (por exemplo, sísmica, perfis, testes de pressão). A construção da verossimilhança envolve considerar tanto a acurácia dos dados quanto o viés de interpretação. Quando disponíveis, dados históricos podem apoiar a estimativa dessas probabilidades, embora sejam raramente formalizados. Em muitos casos, utilizam-se bandas de confiabilidade e análises de sensibilidade para avaliar a robustez das decisões.

Quatro critérios principais determinam se a aquisição de informação é valiosa em um estudo de VOI ([02], [03]):

- **Observável:** os resultados da coleta de informação devem ser conhecidos antes da decisão.
- **Relevante:** a informação deve ter o potencial de alterar as crenças sobre a incerteza associada ao problema.
- **Material:** a informação deve ser capaz de modificar a decisão final.
- **Econômica:** o valor esperado da informação deve exceder o custo de adquiri-la.

O método de VOI garante que esses critérios sejam satisfeitos e pode ser aplicado nas decisões com diferentes níveis de complexidade. Entretanto, modelos mais sofisticados podem ser necessários quando múltiplas incertezas ou distribuições contínuas estão envolvidas.

2.1.3

VOI e o Problema TALL-N

O VOI é definido como o valor máximo que o tomador de decisão deveria pagar pela informação adicional relevante. Sob a hipótese de neutralidade ao risco, o VOI é dado por [03]:

$$VOI = \mathbb{E}[\text{valor com informação}] - \mathbb{E}[\text{valor sem informação}]. \quad (2-6)$$

Se a informação adicional for perfeita, essa quantidade é denominada **Valor da Informação Perfeita** (VOPI) que representa o limite superior de qualquer atividade de coleta de informação. Conforme a terminologia usada na subseção (2.1.1) temos EVPI (Valor Esperado da Informação Perfeita) ou EVII (Valor Esperado da Informação Imperfeita). O valor esperado com informação só pode ser maior do que o valor sem informação se a decisão puder ser alterada em função da informação revelada. Caso o tomador de decisão adote a mesma ação, independentemente do resultado do teste, então $VOI = 0$, tornando a coleta de informação inútil para o problema decisório.

Um problema interessante na análise do VOI é o **problema TALL-N** (*Two-Action Linear-Loss with Normal priors*) que considera um tomador de decisão diante de duas alternativas:

- a_0 : alternativa segura, com payoff constante v ;
- a_1 : alternativa arriscada, com payoff incerto descrito por uma variável aleatória $\tilde{x}$ com média μ e desvio-padrão σ .

Se $\mu < v$, o decisor escolhe a_0 ; se $\mu > v$, escolhe a_1 ; e se $\mu = v$, encontra-se indiferente. O valor esperado sem informação adicional é dado por:

$$\mathbb{E}[\text{valor sem informação}] = \max(v, \mu). \quad (2-7)$$

A Figura 2.3 ilustra o problema TALL-N, onde a variável aleatória $\tilde{x}$ é assumida como normalmente distribuída. A padronização $z = \frac{x-\mu}{\sigma}$ permite definir o coeficiente de divergência:

$$c = \frac{\mu - v}{\sigma}, \quad (2-8)$$

que representa a distância entre as duas alternativas em unidades de desvio-padrão.

A **informação perfeita** permite ao decisor sempre escolher a melhor alternativa conforme o verdadeiro estado da natureza. Assim, o EVPI é definido por:

$$EVPI = E[\max(v, \tilde{x})] - \max(v, \mu). \quad (2-9)$$

No caso normal (TALL-N), obtém-se a seguinte forma fechada [04]:




Figura 2.3: Problema TALL-N com preferência inicial de risco. Fonte: [04].

$$EVPI = \begin{cases} \sigma [\phi(c) - c \Phi(-c)], & \mu \geq v, \\ \sigma [\phi(c) + c \Phi(c)], & \mu < v, \end{cases} \quad (2-10)$$

em que $\phi(\cdot)$ é a densidade da normal padrão e $\Phi(\cdot)$ sua função de distribuição acumulada.

Quando a **informação é imperfeita**, mas correlacionada com o payoff incerto, utilizamos o EVII. Considere um sistema de informação Θ_ρ , cujo sinal θ é normalmente distribuído e correlacionado com $\tilde{x}$ por um coeficiente de correlação $\rho > 0$. Nesse caso, a média condicional é dada por $E[\tilde{x} | \theta] = \mu + \rho\sigma\theta$ que será maior que v enquanto $\theta > (v - \mu)/(\rho\sigma) = -\rho^{-1}c$. Portanto, o EVII é definido por:

$$EVII = E[\max(v, E[\tilde{x} | \theta])] - \max(v, \mu), \quad (2-11)$$

e pode ser escrito na forma fechada como [04]:

$$EVII = \begin{cases} \rho\sigma [\phi(\rho^{-1}c) - \rho^{-1}c \Phi(-\rho^{-1}c)], & \mu \geq v, \\ \rho\sigma [\phi(\rho^{-1}c) + \rho^{-1}c \Phi(\rho^{-1}c)], & \mu < v. \end{cases} \quad (2-12)$$

O valor de EVII dado pela Equação (2-12) é o valor esperado da distribuição que descreve a incerteza no VOI [15]. Quando a correlação é perfeita ($\rho = 1$), temos o caso de informação perfeita, cujos resultados são equivalentes ao EVPI. Por outro lado, a informação imperfeita, com correlação ρ , pode ser interpretada como equivalente ao valor da informação perfeita, mas com um desvio-padrão ajustado $\sigma_{\text{ajustado}} = \rho\sigma$, ou seja:

$$\rho^{-1}c = \frac{\mu - v}{\rho\sigma} \quad (2-13)$$

comparar com a Equação (2-8). Isso significa que a qualidade da informação imperfeita pode ser vista como se fosse informação perfeita, porém mais “difusa”, já que a incerteza é reduzida proporcionalmente a ρ .

O valor do EVII é sempre limitado superiormente pelo EVPI, aproximando-se dele quando $\rho \rightarrow 1$ e tendendo a zero quando $\rho \rightarrow 0$. No limite, quando $c \rightarrow \infty$, obtém-se [04]:

$$\lim_{c \rightarrow \infty} RVOI_{\rho}^* = \rho^2, \quad (2-14)$$

onde o sobrescrito * indica que este é o valor máximo do RVOI (*Relative Value of Information*) para um determinado c . RVOI é definido como a razão entre EVII e EVPI:

$$RVOI_{\rho}^* = \frac{EVII}{EVPI} = \rho^2. \quad (2-15)$$

Portanto, o RVOI expressa diretamente a fração do valor da informação imperfeita em relação ao valor da informação perfeita, sendo determinado pelo quadrado do coeficiente de correlação, isto é, ρ^2 [04]. Na referência [05] temos também a demonstração que $RVOI = \rho^2$ no contexto de perda quadrática e função de regressão linear.

Dado um valor específico de c , o RVOI atinge seu valor máximo quando $c = \sigma/2R$, onde R representa a *risk tolerance* do tomador de decisão e σ o desvio-padrão. Nessa condição, a informação imperfeita possui o maior valor relativo em comparação com a informação perfeita, correspondendo ao caso em que o tomador de decisão está indiferente. Assim, o valor máximo do RVOI é expresso por:

$$RVOI_{\rho}^* = \frac{\ln [2\Phi(-\rho c)]}{\ln [2\Phi(-c)]}, \quad (2-16)$$

Na Figura 2.4 é apresentado o gráfico do valor máximo de $RVOI^*$ em função do coeficiente de divergência c . Observa-se que, para diferentes valores do coeficiente de correlação ρ , o comportamento de $RVOI^*$ evidencia a importância relativa da informação imperfeita em comparação à informação perfeita. Além disso, a figura permite analisar os valores-limite que fornecem interpretações intuitivas sobre o valor da informação em diferentes cenários de risco e preferência do tomador de decisão.

Importante ressaltar que é possível calcular outros dois limites para $RVOI^*$, os quais podem ser visualizados na Figura 2.4. Quando $c \rightarrow 0$, temos que $RVOI_{\rho}^* \rightarrow \rho$, conforme o problema TALL-N, onde $RVOI_{\rho} = \rho$. Por outro lado, quando $c \rightarrow -\infty$, obtém-se $RVOI_{\rho}^* \rightarrow 1$, o que indica que um tomador de decisão avesso ao risco pode valorizar a informação imperfeita quase tanto quanto a informação perfeita, caso a alternativa de *status quo* seja significativamente melhor que a alternativa arriscada. No entanto, o limite que nos interessa é o expresso pela Equação (2-15), pois fornece uma interpretação interessante para o seguinte resultado:

$$EVII = \eta^2 \cdot EVPI \quad (2-17)$$




Figura 2.4: Máximo valor de RVOI em função de $c = \frac{\mu-v}{\sigma}$.

Abordaremos a Equação (2-17) na subseção seguinte, antes, vamos analisar o RVOI no caso geral para o problema TALL-N, razão entre as Equações (2-12) e (2-10), que é dado por [04]:

$$\frac{EVII}{EVPI} = \begin{cases} \rho, & \mu = v \\ \frac{\rho \phi(\rho^{-1}c) - c \Phi(-\rho^{-1}c)}{\phi(c) - c \Phi(-c)}, & \mu > v \\ \frac{\rho \phi(\rho^{-1}c) + c \Phi(\rho^{-1}c)}{\phi(c) + c \Phi(c)}, & \mu < v \end{cases} \quad (2-18)$$

Assim, observa-se que RVOI depende do coeficiente de correlação ρ e do coeficiente de divergência c . No caso em que $\mu = v$, o valor relativo da informação imperfeita em relação à informação perfeita é simplesmente ρ . Já quando $\mu > v$ ou $\mu < v$, a relação passa a depender da interação entre ρ e c . A Figura 2.5 mostra o comportamento de RVOI em relação ao coeficiente de divergência c , dado pela Equação (2-18):

De forma geral, conforme Figura 2.5, o comportamento de $\frac{EVII}{EVPI}$ é simétrico em torno de $c = 0$, diminuindo rapidamente conforme o valor absoluto de c aumenta. Isso significa que, à medida que cresce a divergência entre as alternativas, o valor relativo da informação imperfeita cai de forma significativa, mesmo para correlações elevadas.

2.1.4

Medida de Aprendizagem η^2

A **medida de aprendizagem** η^2 , introduzido por [06], também conhecida por **fator de transferência de valor** [07], pode ser entendido como




Figura 2.5: Valor de RVOI em função de $c = \frac{\mu-v}{\sigma}$.

uma medida que quantifica a efetividade da informação adquirida na redução da incerteza do processo decisório. Esse parâmetro está diretamente associado à redução percentual esperada da variância de uma variável de interesse.

Sejam duas variáveis aleatórias X e S , ambas com médias e variâncias finitas e definidas em um mesmo espaço de probabilidade. A variável X representa, por exemplo, uma incerteza técnica relevante, como o volume de óleo não varrido em uma região do reservatório, e S corresponde à nova informação adquirida (por exemplo, dados sísmicos *time-lapse*). A medida de aprendizagem é então definida por ([06], [07], [08]):

$$\eta^2(X | S) = \frac{\text{Var}[X] - \mathbb{E}[\text{Var}(X | S)]}{\text{Var}[X]}. \quad (2-19)$$

A Equação (2-19) expressa a redução percentual da variância de X proporcionada pela informação S , em relação à variância original sem informação adicional. Em outras palavras, mede o quanto a incerteza é reduzida em termos esperados após a obtenção da nova informação. O valor de η^2 varia entre 0 e 1. Quando $\eta^2 = 0$, a informação é totalmente não informativa, não reduzindo a incerteza; nesse caso, o VOI tende a zero. Por outro lado, quando $\eta^2 = 1$, toda a incerteza é eliminada, o que corresponde ao caso de informação perfeita, em que $VOI = EVPI$.

Na prática, o cálculo exato de η^2 pode ser complexo, pois depende tanto da distribuição de probabilidade da variável X quanto da probabilidade condicional $X|S$. Contudo, sua interpretação é intuitiva: trata-se de uma métrica que indica o ganho esperado de informação em termos de redução da incerteza, permitindo avaliar a relevância e a efetividade da aquisição de novos dados no contexto da tomada de decisão.

Com base no exposto até aqui, podemos considerar que o VOI é equivalente ao EVII, o qual deve ser uma função de η^2 e do EVPI, conforme estabelecido na Equação (2-17). Dessa forma, é possível obter o gráfico do VOI em função de η^2 para diferentes valores de μ (média da variável aleatória): **i)** $\mu < v$, a escolha ótima do tomador de decisão é a_0 (alternativa segura, com *payoff* constante v); **ii)** $\mu > v$, a escolha ótima é a_1 (alternativa arriscada, com *payoff* incerto); **iii)** $\mu = v$, o tomador de decisão encontra-se indiferente entre as duas alternativas. Vale ressaltar que o valor esperado do tomador de decisão sem informação adicional é dado por $\max(v, \mu)$, conforme Equação (2-7) .

A Figura 2.6 apresenta a relação entre VOI e η^2 , ilustrando como o valor da informação depende da redução esperada da variância da variável de interesse em cada um dos cenários decisórios.




Figura 2.6: VOI em função de η^2 .

Ressalta-se que o comportamento observado no gráfico da Figura 2.6 é semelhante ao encontrado em [06], [07] e [15]. É sabido também que a curva muda o comportamento, sem alterar a concavidade, para diferentes valores do *payoff*. Em particular, em [07] é apresentada uma função VOI cujo comportamento linear em relação a η^2 é dado por:

$$VOI \equiv VOII = \begin{cases} VOPI [a + (1 - a)\eta^2], & \text{para } \eta^2 \geq \frac{-a}{1 - a}, \\ 0, & \text{para } \eta^2 < \frac{-a}{1 - a}, \end{cases} \quad (2-20)$$

onde a é um parâmetro linear do modelo (consideraram $a = -0.1$), VOII o valor da informação imperfeita, VOPI o valor da informação perfeita e η^2 a medidade de aprendizagem.

A medida de aprendizagem η^2 é uma medida fundamental também em um contexto bayesiano. Ela expressa a fração da variância total de uma variável aleatória X (estado verdadeiro) que é reduzida (ou explicada) após a observação de uma variável informativa S . Formalmente, sua definição geral é dada pela Equação (2-19), que pode ser reescrita como:

$$\eta^2(X|S) = \frac{\text{Var}[X] - \mathbb{E}[\text{Var}(X|S)]}{\text{Var}[X]} = \frac{\text{Var}(\mathbb{E}[X|S])}{\text{Var}[X]}. \quad (2-21)$$

A Equação 2-21 deriva diretamente da *lei da variância total*:

$$\text{Var}[X] = \mathbb{E}[\text{Var}(X|S)] + \text{Var}(\mathbb{E}[X|S]), \quad (2-22)$$

a qual separa a variância total em duas componentes: (i) a variância média residual que representa a incerteza remanescente após observar S ; e (ii) a variância explicada pela informação contida em S .

Suponha que X e S sejam variáveis aleatórias normais padronizadas e correlacionadas, tal que:

$$\begin{pmatrix} X \\ S \end{pmatrix} \sim \mathcal{N}\left(\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix}\right), \quad (2-23)$$

onde ρ é o coeficiente de correlação linear entre X e S . Assim, para o caso normal bivariado, a distribuição condicional de X dado $S = s$ é também normal:

$$X|S = s \sim \mathcal{N}(\rho s, 1 - \rho^2). \quad (2-24)$$

As propriedades de esperança e variância condicionais são dadas por:

$$\mathbb{E}[X|S] = \rho S, \quad \text{Var}(X|S) = 1 - \rho^2. \quad (2-25)$$

Sabendo que $\text{Var}[X] = \text{Var}[S] = 1$, podemos calcular:

$$\text{Var}(\mathbb{E}[X|S]) = \text{Var}(\rho S) = \rho^2 \text{Var}[S] = \rho^2, \quad (2-26)$$

e portanto:

$$\eta^2(X|S) = \frac{\text{Var}(\mathbb{E}[X|S])}{\text{Var}[X]} = \frac{\rho^2}{1} = \rho^2. \quad (2-27)$$

Logo, no caso normal bivariado, a medida de aprendizagem é igual ao quadrado da correlação entre a variável X e a informação adquirida S . Essa relação é intuitiva: quanto mais correlacionada a informação S estiver com o estado X , maior será a fração da variância total explicada, e consequentemente, maior o valor potencial da informação.

No modelo TALL-N, analisado na subseção anterior e amplamente utilizado em análise de decisão sob incerteza, a variável de interesse X segue uma distribuição normal a priori:

$$X \sim \mathcal{N}(\mu_0, \sigma_0^2), \quad (2-28)$$

e a informação observada é modelada como uma variável S (por exemplo, um teste sísmico) e afetada por ruído aditivo gaussiano (ruído da observação):

$$S = X + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \sigma_\varepsilon^2). \quad (2-29)$$

Nesse contexto, o fator de transferência de valor é dado por:

$$\eta^2 = \frac{\sigma_0^2}{\sigma_0^2 + \sigma_\varepsilon^2}, \quad (2-30)$$

onde σ_0^2 é a incerteza inicial (a priori) e σ_ε^2 é a incerteza da medição (ruído). Sendo assim, η^2 mede quanto da incerteza inicial é resolvida pela informação S . Temos também que a correlação linear entre o valor de X e a informação observada S é:

$$\rho = \frac{\sigma_0}{\sqrt{\sigma_0^2 + \sigma_\varepsilon^2}}. \quad (2-31)$$

Assim, das Equações (2-30) e (2-31), obtemos a relação direta:

$$\eta^2 = \rho^2. \quad (2-32)$$

Portanto, no contexto do modelo TALL-N, a qualidade da informação é determinada pela correlação entre o valor de X e a informação adquirida S . Quanto maior ρ , maior é η^2 e, consequentemente, maior é o Valor da Informação.

A Figura 2.7 apresenta o resultado de uma simulação empírica comparando o valor teórico e o valor estimado de $\eta^2(X|S)$ para diferentes níveis de correlação ρ . Foram geradas amostras bivariadas normais com correlação controlada e calculado, para cada valor de ρ , a fração da variância total de X explicada por S , utilizando a definição da Equação 2-21:

- Os pontos vermelhos representam os valores empíricos de η^2 , calculados a partir de amostras simuladas.
- A linha azul tracejada mostra os valores teóricos, baseados na relação analítica conforme a Equação 2-32.




Figura 2.7: Valor empírico e teórico de $\eta^2(X|S)$ para diferentes níveis de correlação ρ .

Os resultados empíricos coincidem quase perfeitamente com a curva teórica, confirmando que, para variáveis gaussianas correlacionadas, a proporção da variância explicada pela informação é exatamente o quadrado da correlação. Isso reforça a interpretação de η^2 como uma medida da qualidade da informação: quanto mais forte a correlação, maior a fração de incerteza eliminada.

A Figura 2.8 ilustra graficamente a decomposição da variância total de X em duas componentes: a parcela explicada pela informação ($\text{Var}(\mathbb{E}[X|S])$) e a parcela residual ($\mathbb{E}[\text{Var}(X|S)]$). O eixo horizontal representa a correlação ρ , enquanto o eixo vertical mostra a fração da variância total (normalizada, $\text{Var}[X] = 1$):




Figura 2.8: Decomposição da variância total em função da correlação ρ .

- A curva verde representa a variância explicada pela informação, proporcional a ρ^2 .
- A curva azul representa a variância residual, proporcional a $(1 - \rho^2)$.
- A linha vermelha tracejada indica a variância total normalizada ($\text{Var}[X] = 1$).

À medida que a correlação ρ aumenta, a fração de variância explicada (curva verde) cresce, enquanto a variância residual (curva azul) diminui. Quando $\rho = 0$, toda a incerteza permanece; quando $\rho = 1$, toda a incerteza é eliminada. Essa decomposição ilustra de maneira clara a essência da medida de aprendizagem η^2 , representando a proporção da incerteza inicial que é resolvida pela informação adquirida.

2.1.5

Valor da Informação Sequencial

Conforme é sabido, a exploração de petróleo envolve elevados níveis de incerteza geológica, operacional e econômica. Decisões inadequadas na fase de delimitação (*appraisal*) podem levar a investimentos em poços de alto custo com baixo retorno, ou ainda à subexploração de reservas economicamente viáveis. Nesse contexto, o Valor da Informação, conforme visto na seção anterior, surge como uma ferramenta quantitativa essencial para avaliar se a aquisição de novos dados, por meio de poços de avaliação, testes de formação ou métodos geofísicos adicionais, justifica o investimento em função do impacto que tais informações podem ter sobre decisões futuras.

O **Valor da Informação Sequencial** (VOSI, *Value of Sequential Information*) expande o conceito clássico de VOI ao considerar que a informação é adquirida em diferentes estágios, e que as decisões subsequentes podem ser ajustadas de acordo com os resultados parciais observados. Diferentemente de um VOI estático, que assume um único ponto de coleta de dados antes da decisão final, o VOSI modela um processo dinâmico, no qual o tomador de decisão pode:

- optar por perfurar um poço adicional se os resultados iniciais forem promissores;
- redirecionar o programa de avaliação caso os dados revelem incertezas críticas não previstas;
- abandonar ou postergar o desenvolvimento se os sinais forem negativos.

Essa flexibilidade gera valor adicional, pois permite incorporar **aprendizado progressivo** ao processo de delimitação do campo. A formulação básica do VOI, conforme Equação (2-6), pode ser expressa por:

$$VOI = \mathbb{E}[X | S] - \mathbb{E}[X], \quad (2-33)$$

onde $\mathbb{E}[X | S]$ representa o valor esperado do projeto com informação adicional S , ou seja, o valor esperado posterior e, $\mathbb{E}[X]$, representa o valor esperado sem informação, isto é, o valor esperado a priori, que para um problema de decisão, pode ser obtido com [09]:

$$\mathbb{E}[X] = \sum_{i=1}^n \max_{a_i \in A_i} \left\{ \mathbb{E}[v(x_i, a_i)] \right\}, \quad (2-34)$$

onde x_i representa os estados da natureza, $a_i \in A_i$ as alternativas disponíveis e $v(x_i, a_i)$ o valor associado à decisão a_i sob o estado x_i .

Por razões didáticas, vejamos um exemplo retirado de [09]: considere a perfuração de dois poços S_1 e S_2 . Suponha que o tomador de decisão opte pela aquisição da primeira perfuração S_1 , com a possibilidade de posteriormente realizar também a perfuração S_2 . Para alguns resultados obtidos a partir da perfuração do poço S_1 , o decisor pode não considerar necessária a realização da segunda perfuração. Para outros resultados, ele ou ela pode, de fato, optar por realizar a perfuração do poço S_2 . Assim, o valor de um esquema de perfuração sequencial não pode ser inferior ao valor obtido ao realizar ambas as perfurações de uma só vez, isto é, uma estratégia estática de perfuração. Um decisor neutro ao risco pode determinar a melhor sequência de perfuração ao maximizar o valor esperado. No caso de dois poços, o tomador de decisão possui as seguintes alternativas:

- perfurar apenas o poço S_1 e encerrar o programa;
- perfurar o poço S_1 e, em seguida, realizar a perfuração do poço S_2 ;
- perfurar apenas o poço S_2 e encerrar o programa;
- perfurar o poço S_2 e, em seguida, realizar a perfuração do poço S_1 .

Supondo que o poço S_1 tenha sido perfurado primeiro, com $p(S_1)$ a probabilidade de ser observado um resultado favorável, o valor esperado posterior (estático) é dado por [09]:

$$\mathbb{E}[X | S_1] = \int \sum_{i=1}^n \max_{a_i \in A_i} \{ \mathbb{E}[v(x_i, a_i) | S_1] \} p(S_1) dS_1. \quad (2-35)$$

O cálculo do valor esperado posterior requer a determinação do valor esperado condicional $\mathbb{E}[v(x_i, a_i) | S_1]$, bem como da função densidade de probabilidade marginal $p(S_1)$, a qual pode ser obtida a partir da distribuição a priori $p(X)$ e da verossimilhança $p(S_1 | X)$ por meio do Teorema de Bayes, Equação (2-1).

Nos testes sequenciais, o integrando da solução torna-se mais complexo, pois é necessário considerar todas as possíveis sequências de aquisição de informação. O tomador de decisão somente irá realizar a perfuração do segundo poço se o valor adicional, descontado o custo do segundo poço P_2 , for maior do que o valor do primeiro poço isolado, isto é, temos a seguinte condição:

$$\int_{S_2} \sum_{i=1}^n \max_{a_i \in A_i} \{ \mathbb{E}[v(x_i, a_i) \mid S_1, S_2] \} p(S_2 \mid S_1) dS_2 - P_2 > \sum_{i=1}^n \max_{a_i \in A_i} \{ \mathbb{E}[v(x_i, a_i) \mid S_1] \}. \quad (2-36)$$

O lado esquerdo da Equação (2-36) é denominado *teste continuado*, enquanto o lado direito está associado à decisão do agente em interromper o programa de perfuração após perfurar o primeiro poço. Dessa maneira, o valor esperado posterior à perfuração do primeiro poço, tendo a opção de continuar com a perfuração do segundo poço, torna-se:

$$\mathbb{E}[X \mid S_2, S_1] = \int \max \left\{ \int_{S_2} \sum_{i=1}^n \max_{a_i} \left\{ \mathbb{E}[v(x_i, a_i) \mid S_1, S_2] \right\} p(S_2 \mid S_1) dS_2 - P_2, \right. \\ \left. \sum_{i=1}^n \max_{a_i} \left\{ \mathbb{E}[v(x_i, a_i) \mid S_1] \right\} \right\} p(S_1) dS_1. \quad (2-37)$$

e, sendo o tomador de decisão neutro ao risco, o VOI é definido como a diferença entre os valores a posteriori e a priori, conforme a Equação (2-33). Este VOI deve ser comparado ao custo P_1 do poço S_1 . Se o VOI for maior do que esse custo, torna-se justificável realizar a perfuração sequencial iniciando pelo poço S_1 . O esquema ótimo de perfuração sequencial pode, entretanto, indicar que a melhor estratégia seja iniciar pela perfuração do poço S_2 e, em seguida, executar a perfuração do poço S_1 . Os valores a posteriori de todas as estratégias devem ser avaliados e comparados após a incorporação dos custos das perfurações.

De forma mais geral, para perfurações sequenciais $S_j, j = 1, \dots, m$, o VOI pode ser escrito como uma sequência de integrais e maximizações intercaladas. As integrais (ou somas, no caso de espaço amostral discreto) são realizadas sobre os resultados observados das perfurações. As maximizações, por sua vez, são realizadas sobre as alternativas de continuar ou interromper o processo de perfuração. A situação pode ser ilustrada por meio de uma árvore de decisão parcialmente desenhada, apresentada na Figura 2.9. Em cada ramo da árvore, o tomador de decisão pode optar por continuar a perfuração ou interromper.

O valor posterior de VOSI iniciando pela perfuração do poço S_{j1} é dado por:




Figura 2.9: Ilustração parcial de uma campanha de perfuração sequencial. Fonte [10].

$$\mathbb{E}[\cdot \mid S_{j1}] = \int \max \left\{ \max_{j2 \neq j1} \{ContVal_{j2}(S_{j1})\}, \sum_{i=1}^n \max_{a_i} \{\mathbb{E}[v(x_i, a_i) \mid S_{j1}]\} \right\} p(S_{j1}) dS_{j1} \quad (2-38)$$

onde o valor de continuação ($ContVal$), no caso de mais perfurações sequenciais, é definido como:

$$ContVal_{j2}(S_{j1}) = \int_{S_{j2}} \max \left\{ \max_{j3 \neq j1, j2} \{ContVal_{j3}(S_{j1}, S_{j2})\}, \sum_{i=1}^n \max_{a_i} \{\mathbb{E}[v(x_i, a_i) \mid S_{j1}, S_{j2}]\} \right\} p(S_{j2} \mid S_{j1}) dS_{j2} - P_{j2}. \quad (2-39)$$

Devido ao encadeamento associado aos valores de continuação, a obtenção computacional do valor a posteriori e do VOI revela-se, em geral, altamente complexa. A solução para a formulação geral é fornecida pela programação dinâmica. Para modelos pequenos e problemas simplificados, essa solução pode ser obtida exatamente. Entretanto, para modelos de maior porte, estratégias heurísticas são necessárias na prática.

Na delimitação de campos de petróleo, os custos de perfuração e aquisição de dados são elevados, mas seu potencial de impacto estratégico também é significativo. A análise do VOSI permite:

- Priorizar locais de perfuração que maximizem o aprendizado geológico, não apenas a produção imediata;
- Reduzir riscos de sobrecapitalização, evitando investimentos antecipados em poços ou plataformas antes da confirmação do potencial econômico;
- Otimizar a sequência de perfuração, de forma que poços de menor custo e maior capacidade de aprendizado sejam executados primeiro, servindo como filtros para decisões futuras;
- Integrar incertezas múltiplas (volume, qualidade do reservatório, custos de operação e preço do petróleo) em uma estrutura unificada de apoio à decisão.

O uso do VOSI fortalece o processo decisório em três dimensões principais. Na dimensão econômica, contribui para a maximização do VPL esperado do campo, ao considerar diferentes caminhos de informação. Na dimensão operacional, permite um planejamento mais eficiente na alocação de recursos de perfuração e aquisição de dados. Por fim, na dimensão estratégica, aumenta a robustez das decisões, possibilitando que as companhias mantenham flexibilidade diante da incerteza e ajustem os planos de desenvolvimento conforme novos dados são adquiridos. Dessa forma, a aplicação do VOSI na delimitação de campos de petróleo não apenas reduz a probabilidade de erros críticos, mas também aumenta a chance de capturar valor no longo prazo, equilibrando risco, custo e aprendizado.

Se nenhuma informação geológica for obtida após a perfuração de cada poço, as distribuições das propriedades geológicas da região de perfuração permanecem inalteradas, assim como o valor esperado de cada poço. Nesse caso, apenas os poços com valor esperado positivo a priori serão perfurados, e a sequência de perfuração deixa de ter importância. Ao conhecer as propriedades geológicas de uma determinada área, as distribuições geológicas das demais regiões são atualizadas, o que pode modificar seus respectivos valores esperados. Alguns poços podem ter seu valor esperado alterado de negativo para positivo (ou vice-versa). Selecionar o próximo poço a ser perfurado com base nesses valores esperados atualizados adiciona valor ao processo de decisão da campanha de perfuração. Nesse contexto, conforme já discutido anteriormente, a informação somente tem valor se contribuir para a escolha do próximo poço ou para a decisão de interromper a campanha de perfuração. Para gerar valor, a informação precisa estar disponível antes da decisão (ser observável), deve ser relevante para o problema em questão e deve possuir a capacidade de alterar a decisão de acordo com seu conteúdo (ser material), conforme discutido em [01] e [03].

2.1.6

Modelo de Decisão Sequencial

O **Modelo de Decisão Sequencial** (SDM, do inglês *Sequential Decision Model*) é um arcabouço fundamental para problemas em que decisões devem ser tomadas em estágios sucessivos, sob incerteza e com aprendizado ao longo do processo. No contexto da exploração e avaliação de poços de petróleo o SDM permite representar a sequência de escolhas de perfuração, incorporando o fato de que os resultados observados em estágios anteriores influenciam as decisões futuras. A representação gráfica de um SDM pode ser feita de várias maneiras, vamos salientar as três principais. Uma forma compacta é ilustrada na Figura 2.10, em que quadrados representam decisões (escolha das possíveis alternativas) e círculos representam os possíveis resultados incertos da alternativa escolhida [11]. O tempo avança da esquerda para a direita, sendo que o aumento do índice indica os estágios de tomada de decisão, também chamados de épocas de decisão. Do estágio de decisão anterior para o próximo, o resultado incerto da alternativa escolhida é revelado, o que significa que o tomador de decisão adquire aprendizado entre os estágios. Esse aprendizado tem o potencial de alterar o valor esperado das alternativas do estágio seguinte. A mudança no valor esperado das alternativas pode levar a uma escolha diferente em função do conhecimento adquirido previamente.




Figura 2.10: Representação esquemática do SDM. Fonte [11].

Outra forma de representação do SDM é ilustrada na Figura 2.11, onde cada alternativa tem um certo número de resultados e cada resultado é a entrada para a próxima decisão. Esse encadeamento explicita o caráter sequencial e probabilístico do problema, mas também revela sua complexidade combinatória, conhecida como maldição da dimensionalidade (*curse of dimensionality*).

O objetivo central do SDM é determinar a **política ótima**, ou seja, a sequência de escolhas que maximiza o valor esperado da campanha de perfuração. Para resolver esse problema, utiliza-se a Programação Dinâmica Estocástica (SDP, do inglês *Stochastic Dynamic Programming*), formalizada originalmente por Bellman em [13]. A solução se baseia na equação de Bellman, que define o valor ótimo em cada nó de decisão como o máximo valor esperado




Figura 2.11: Representação esquemática alternativa do SDM. Fonte [12].

dentre as alternativas possíveis, levando em conta tanto a recompensa imediata quanto o valor futuro associado às escolhas subsequentes. A equação de Bellman é dada matematicamente por [12]:

$$V_i(\omega_i) = \max_{a \in A(i)} \left(\sum_{x \in X(a)} [P(x|\omega_i) (r_a^x + \delta V(\omega_i^{a,x}))] \right), \quad (2-40)$$

onde $V_i(\omega_i)$ é o valor esperado ótimo no nó de decisão i , condicionado ao estado de conhecimento ω_i . Cada alternativa a possui um conjunto de possíveis resultados $X(a)$, cada um com probabilidade de ocorrência $P(x|\omega_i)$ e recompensa imediata r_a^x . O termo $V(\omega_i^{a,x})$ representa o valor esperado futuro (valor de continuação) quando a sequência de decisão segue o caminho a, x , corrigido pelo fator de desconto $\delta = (1 + r)^{-1}$, sendo r a taxa de desconto. Embora o SDP garanta a solução ótima, sua aplicação direta é limitada a problemas de pequeno porte, devido ao crescimento exponencial do espaço de estados, alternativas e desfechos. Para problemas maiores, heurísticas e métodos aproximativos são necessários, mas o SDM e a equação de Bellman continuam sendo a base conceitual que estrutura a formulação do problema.

A terceira forma de representação gráfica do SDM é a já conhecida árvore de decisão. Esse tipo de representação é mais detalhado e facilita a visualização da mecânica de cada decisão individual, mostrando de forma explícita como alternativas e resultados se encadeiam ao longo dos estágios. No entanto, a complexidade do modelo cresce rapidamente com o número de alternativas disponíveis, o conjunto de possíveis resultados e o número de estágios considerados. A Figura 2.12 mostra um simples SDM com dois estágios (decisões). Cada decisão possui duas alternativas, e cada alternativa se desdobra em dois possíveis resultados. Esse exemplo ilustra de forma compacta como a árvore de decisão explicita o encadeamento das escolhas e incertezas, destacando, ao mesmo tempo, o desafio do crescimento combinatório à medida que o problema se torna mais realista.




Figura 2.12: Árvore de decisão representando um simples SDM. Fonte [11].

Em cada estágio, o número de nós de decisão aumenta, e estes podem ser identificados por $D_{s,j}$, onde s representa o número do estágio e j a posição relativa dentro do estágio. O conjunto de alternativas possíveis em cada nó, denotado por $A(D_{s,j})$, pode variar conforme o contexto da decisão. De forma análoga, cada resultado incerto x pertence ao conjunto de possíveis resultados $X(a)$, que depende da alternativa escolhida a , a qual, por sua vez, está associada ao nó de decisão $D_{s,j}$.

A Equação (2-40) é aplicada recursivamente em todos os nós de decisão, iniciando no último estágio e sendo progressivamente utilizada em direção ao primeiro estágio via processo SDP. A utilização do SDP no modelo de decisão apresentado na Figura 2.12 pode ser exemplificada conforme ilustrado na Figura 2.13.




Figura 2.13: Exemplo do processo SDP. Fonte [11].

A Figura 2.14 mostra um nó de decisão genérico tal como os nós apresentados nas Figuras 2.12 e 2.13. Este nó não está no último estágio, o que significa que novos nós de decisão continuam a partir de cada um dos ramos de resultado.




Figura 2.14: Nó de decisão genérico. Fonte [11].

A principal diferença de um nó de decisão genérico para um nó de decisão genérico no último estágio é que, para obter o valor esperado de cada alternativa, utiliza-se a média ponderada pelas probabilidades de ocorrência, considerando tanto as recompensas imediatas r_a^x quanto o termo adicional $\delta V(\omega_i^{a,x})$, que representa o valor esperado futuro. O estado de conhecimento

posterior $\omega_{i+1} = \omega_i^{a,x}$ é atualizado de acordo com a informação revelada pelo resultado x , quando a alternativa a é escolhida. A Equação (2-40), equação de Bellman, sintetiza o método e permite a aplicação recursiva do processo SDP.

O valor mais importante da política ótima é o valor esperado da campanha antes do início da perfuração. Isso significa que, com base no conhecimento prévio ω_0 , espera-se obter $V_0(\omega_0)$ a partir da sequência ótima de perfuração, aproveitando a informação geológica espacial disponível antes de cada decisão. Todas as probabilidades e valores esperados $V_i(\omega_i)$, calculados ao longo do processo da programação dinâmica, são armazenados juntamente com as regras de decisão e são considerados parte integrante da política ótima. [14] apresenta uma política ótima contendo todas essas informações em um caso hipotético com três poços candidatos (A, B, C), cada um com quatro possíveis resultados categóricos ($\#0, \#1, \#2, \#3$), associados à função de valor $r = [-10, -5, 5, 10]$, conforme ilustrado na Figura 2.15.




Figura 2.15: Análise simples da política ótima para três poços. Fonte [11].

É importante observar que, em algumas situações, a sequência de perfuração pode ser interrompida precocemente devido aos resultados observados. Além disso, algumas sequências de perfuração podem se repetir para diferentes combinações de resultados. Uma alternativa para representar a política ótima é listá-la em termos de eventos conjuntos associados a probabilidades conjuntas, como mostrado no lado direito da Figura 2.15.

Existe, portanto, um grande potencial em extrair percepções decisórias e agregar valor aplicando o processamento heurístico dos métodos à política ótima, especialmente em modelos de grande porte, nos quais a representação gráfica direta da política ótima torna-se inviável.

2.2

Valor da Flexibilidade

A flexibilidade em projetos de E&P pode ser entendida como a capacidade de ajustar decisões à medida que novas informações surgem ou que incertezas se resolvem ao longo do tempo. Esse conceito está intimamente ligado à teoria das Opções Reais, na qual o gestor preserva o direito, mas não a obrigação, de modificar o curso de ação de acordo com as condições futuras. Assim, o **Valor da Flexibilidade** (VoF) corresponde ao benefício econômico de manter abertas as alternativas de decisão diante das incertezas.

Antes de decidir pela aquisição de informação é importante avaliar o valor da flexibilidade, ou seja, a capacidade de responder adequadamente às incertezas à medida que elas são resolvidas. A análise do VoF, análoga ao VOI, tem como objetivo determinar se o benefício esperado da flexibilidade supera seu custo. De forma geral, a flexibilidade pode gerar valor nas seguintes circunstâncias [16]:

- i) Quando não é possível adquirir informação para reduzir a incerteza;
- ii) Quando é mais barata do que obter informação;
- iii) Para lidar com a incerteza residual após a obtenção de informação;
- iv) Quando ela própria cria valor.

Nas três primeiras situações, o objetivo principal é mitigar riscos (impactos negativos) associados à incerteza; na última, busca-se explorá-la para gerar ganhos.

O ganho de valor por meio da flexibilidade depende da capacidade de pensar criativamente sobre como dividir decisões e planos de projeto em etapas, permitindo aprendizado e adaptação entre elas. Por exemplo, pode-se dividir os investimentos em duas fases, permitindo a opção de avançar para a segunda fase apenas se os resultados iniciais forem promissores. A ideia é ilustrada na Figura 2.16.




Figura 2.16: Divisão de decisões para aprender antes de avançar. Fonte [01].

O benefício dessa abordagem deve superar os custos envolvidos, tanto o custo da flexibilidade em si quanto eventuais atrasos e perdas associadas ao valor do dinheiro no tempo [16]. Como exemplo, o risco de superestimar o volume original de óleo no reservatório pode ser reduzido ao adiar a decisão de expandir a capacidade de processamento até que alguns poços de desenvolvimento tenham sido perfurados. Por outro lado, o potencial positivo pode ser explorado planejando *slots* adicionais na plataforma, a serem utilizados apenas se o reservatório for maior que o esperado [16].

O VoF não é apenas uma técnica de cálculo de valor, mas também uma forma de pensar sobre como lidar com a incerteza. Seus cálculos são, em geral, mais simples do que os do VOI. Pode ser considerada uma versão mais formal de uma abordagem em que as decisões são estruturadas com base em uma análise quantitativa das incertezas e de seus impactos econômicos. Embora muitas aplicações do VoF ainda se concentrem na mitigação de riscos, seu verdadeiro potencial está em servir como uma ferramenta para maximizar o valor de projetos sob incerteza.

Um exemplo didático encontrado em [16], apresenta todo o potencial da flexibilidade para gerar valor e mostra, de forma um tanto contraintuitiva, que quanto maior a incerteza, maior o valor. A ideia é determinar o valor de uma unidade de processamento e exportação que permita acelerar a produção quando o preço do petróleo estiver alto e reduzi-la quando o preço estiver baixo. O autor pede para suspender o julgamento sobre a (im)praticabilidade de tal sistema e focar no potencial da flexibilidade.

A Figura 2.17a mostra o perfil de produção esperado para o desenvolvimento sem qualquer relação entre o preço do petróleo e a taxa de produção. Para esta ilustração, todas as incertezas, exceto o preço, foram removidas. O VPL deste caso é de US\$ 282 milhões.




Figura 2.17: Valor da flexibilidade: a) curva de produção, b) Redução da produção em períodos de preço baixo, c) Produção reduzida (acelerada) com preço baixo (alto), d) Uma previsão de preço com reversão à média, e) Valor do projeto com a magnitude da incerteza, f) Valor esperado do projeto em função da incerteza no preço. Fonte [11].

A Figura 2.17d apresenta uma realização de um modelo estocástico de preço com reversão à média e sem tendência de longo prazo. Já a Figura 2.17b mostra o perfil no caso em que a única capacidade é desacelerar a produção quando o preço do petróleo está baixo. O VPL neste cenário é de US\$ 303 milhões, mesmo considerando o impacto da postergação de receita devido ao desconto temporal. Se também houver a capacidade de acelerar a produção quando o preço do petróleo estiver alto, obtém-se o perfil mostrado na Figura 2.17c. O VPL neste caso sobe para US\$ 486 milhões, o que representa um aumento de US\$ 204 milhões em relação ao caso sem flexibilidade.

Os resultados acima correspondem a um preço do petróleo com desvio padrão de US\$ 3,6. Variando o desvio padrão, observa-se, conforme mostrado na Figura 2.17e, que o VPL aumenta à medida que cresce a magnitude da incerteza no preço do petróleo. Para obter uma visão mais precisa do valor esperado desse esquema, é necessário eliminar o efeito de uma realização específica. A Figura 2.17f apresenta os resultados das simulações em múltiplas realizações, calculando-se o VPL médio para cada nível de desvio padrão.

Retornando à questão da praticidade, [16] observa que pode não ser viável projetar um sistema exatamente assim. Entretanto, seu potencial valor, aliado a uma mentalidade baseada em Opções Reais, pode inspirar soluções factíveis, como contratar uma opção sobre capacidade adicional de armazenamento e uma planta de processamento escalável. Além disso, com base na estimativa da variabilidade do preço do petróleo, é possível definir um limite sobre quanto pagar por essa flexibilidade. Vale notar que, se a única incerteza considerada no preço do petróleo fosse em torno de sua média de longo prazo, tal esquema não geraria valor. Contudo, ao reconhecer e modelar variações de curto prazo em torno dessa média, revela-se uma fonte de criação de valor. Além disso, quando são utilizadas estratégias de proteção financeira para gerenciar a incerteza do preço, o resultado é apenas a redução da volatilidade da receita, e não a criação de valor [16].

Quando aplicados por meio de técnicas usuais de árvores de decisão e simulação, o VOI e o VoF oferecem meios práticos e amplamente aplicáveis de obter muitos dos benefícios associados à abordagem de Opções Reais. Assim, o pensamento fundamentado em Opções Reais amplia seu escopo de aplicação, evoluindo da simples avaliação de valor para a geração efetiva de valor.

2.3

Incertezas Técnicas

A **incerteza geológica**, também chamada de **incerteza técnica**, refere-se à falta de conhecimento completo sobre as características físicas da subsuperfície, como estrutura das camadas, propriedades petrofísicas, continuidade dos reservatórios, contatos de fluidos e permeabilidade. Essa incerteza decorre do fato de que os volumes rochosos não podem ser observados diretamente, sendo inferidos a partir de dados limitados, como perfis de poço, sísmica e amostras de testemunhos. Na indústria de petróleo e gás, essa incerteza é uma das principais fontes de variabilidade técnica, pois influencia diretamente nas estimativas de volume recuperável, curvas de produção, desempenho de poços e viabilidade econômica dos projetos. Por isso, é comum utilizar o termo **incerteza técnica** para distingui-la de outras formas de incerteza, como as incertezas

de mercado (preço do petróleo, custos, taxas de câmbio) e incertezas políticas (regulação, tributos, licenciamento).

A incerteza geológica é usualmente representada por modelos geológicos alternativos ou realizações estocásticas, geradas por métodos geoestatísticos que reproduzem a variabilidade espacial das propriedades do reservatório. Cada realização representa uma possível configuração do reservatório, permitindo avaliar a sensibilidade das decisões de engenharia, como posicionamento de poços e estratégias de injeção, frente à variabilidade geológica. Sendo assim, compreender e quantificar a incerteza geológica é essencial para a tomada de decisão sob incerteza, um planejamento robusto e uma avaliação econômica realista dos projetos de E&P.

Nessa proposta de tese, o **modelo Egg** será utilizado nas simulações preliminares para incorporar a incerteza geológica nos perfis de produção, conforme ilustrado na Figura 2.18. O modelo Egg é um *benchmark* sintético utilizado em estudos de simulação de reservatórios, introduzido originalmente por [17] e posteriormente padronizado por [18]. O modelo é composto por 25.200 células, das quais 18.533 estão ativas, formando um reservatório com formato de “ovo” (*egg-shaped*) após a exclusão das células inativas. Cada bloco possui dimensões de 8m x 8m x 4m, resultando em um reservatório de aproximadamente 480m x 480m x 28m, discretizado em sete camadas verticais. A configuração padrão inclui oito poços injetores e quatro produtores verticais e totalmente penetrantes.




Figura 2.18: Modelo Egg 3D: distribuição de permeabilidade.

A arquitetura do reservatório apresenta canais sinuosos de alta permeabilidade, embutidos em uma matriz de baixa permeabilidade, representando a complexidade geológica típica de ambientes deposicionais fluviais. As sete camadas exibem forte correlação vertical, tornando o campo de permeabilidade praticamente bidimensional. O modelo não possui aquífero nem capa de gás, resultando em produção primária desprezível e tornando a injeção de água o principal mecanismo de recuperação. A Tabela 2.1 apresenta as propriedades gerais para o modelo Egg.

Tabela 2.1: Propriedades gerais do modelo Egg.

Propriedade	Descrição / Valor
Dimensão da grade	$60 \times 60 \times 7 = 25\,200$ células
Células ativas	18 533
Tamanho das células	$8(x)m \times 8(y)m \times 4(z)m$
Tamanho do reservatório	$480m \times 480m \times 28m$
Número de camadas	7 (forte correlação vertical)
Número de realizações	101 (1 determinística + 100 estocásticas)
Poços	12 (8 injetores + 4 produtores)
Aquífero / Capa de gás	Ausentes
Mecanismo de recuperação	Injeção de água (<i>waterflooding</i>)
Período de simulação	3 600 dias (10 anos)
Saturação inicial de água	0,1 (irredutível)
Estrutura de permeabilidade	Canais de alta k em matriz de baixa k
Disponibilidade de dados	Público.

O conjunto padrão do modelo Egg consiste em 101 realizações equiprováveis de permeabilidade, uma determinística e cem estocásticas, geradas no intuito de imitar padrões meandantes de rios. Cada realização representa uma estrutura fluvial distinta, permitindo avaliar algoritmos sob incerteza geológica. Por isso, o modelo Egg é amplamente utilizado como base de testes para métodos de otimização de produção, ajuste histórico e gestão de reservatórios em malha fechada. Como a camada superior contém 3.600 blocos de grade, dos quais 2.491 são ativos, o número de possíveis localizações dos poços produtores é igual a 2.491. As diferentes realizações de permeabilidade exibem padrões distintos de canais, com variações de sinuosidade e orientação, fornecendo um campo de incerteza representativo. A Figura 2.19 ilustra a distribuição espacial da permeabilidade na camada superior para 25 realizações do modelo Egg. Essas realizações foram selecionadas aleatoriamente a partir do conjunto original de 101 realizações.




Figura 2.19: Mapas de permeabilidade da camada superior para 25 realizações.

Detalhes das propriedades de geologia, fluido e operacional para o modelo Egg estão sumarizadas na Tabela 2.2. Notadamente, o modelo de Corey é adotado para o cálculo das permeabilidades relativas do óleo e da água, com expoentes de Corey e valores limites específicos listados conforme indicado em [18].

Tabela 2.2: Propriedades do reservatório/fluidos para o modelo Egg.

Propriedade	Valor	Unidade
Taxa máxima de injeção de água	79,5	m ³ /dia
Pressão de fundo dos produtores	$39,5 \times 10^6$	Pa
Expoente de Corey para o óleo	4	—
Expoente de Corey para a água	3	—
Saturação de água conata	20	%
Saturação inicial de água	10	%
Saturação residual de óleo	10	%
Permeabilidade relativa final do óleo	0,8	—
Permeabilidade relativa final da água	0,75	—
Pressão capilar	0	Pa
Porosidade	0,2	—
Pressão do reservatório	40×10^6	Pa
Compressibilidade do óleo	$1,0 \times 10^{-10}$	Pa ⁻¹
Compressibilidade da água	$1,0 \times 10^{-10}$	Pa ⁻¹
Compressibilidade da rocha	0	Pa ⁻¹
Viscosidade do óleo	$5,0 \times 10^{-3}$	Pa · s
Viscosidade da água	$5,0 \times 10^{-3}$	Pa · s
Tempo de simulação	3 600	dias

Os perfis de produção de óleo e água da versão determinística (modelo de referência), ao longo de um período de simulação de 3.600 dias (10 anos), são apresentados na Figura 2.20.




Figura 2.20: Taxas de produção de óleo e água para os quatro poços produtores.

Durante a fase inicial de produção, não é observada produção de água, pois a saturação inicial de água é definida como 0, 1, correspondente à saturação irreduzível. Após o início da produção de água, a taxa de produção de óleo apresenta uma queda acentuada, indicando a ocorrência do avanço de água (water breakthrough). O tempo de avanço varia entre os poços produtores, evidenciando a heterogeneidade do reservatório. Portanto, a previsão confiável do tempo de avanço de água para cada poço produtor é essencial para um gerenciamento eficiente do reservatório e otimização da produção. Assim, o modelo Egg oferece uma plataforma controlada e realista para a avaliação de métodos de tomada de decisão, estratégias de otimização e técnicas de quantificação de incertezas em engenharia de reservatórios.

2.4

Incerteza do Mercado

Na seção anterior, foi discutida a incerteza técnica, associada à caracterização do modelo geológico e às limitações inerentes à representação do reservatório. Nesta seção, o foco recai sobre as incertezas de natureza econômica, com ênfase nas variáveis de mercado que influenciam diretamente o desempenho financeiro dos projetos de E&P.

Entre as principais incertezas de mercado, nesse estudo vamos considerar duas fontes: o **custo operacional variável** e o **preço do petróleo**, ambas com papel determinante na avaliação econômica de projetos na indústria de petróleo. A volatilidade dessas variáveis impacta de forma significativa a atratividade e o risco dos investimentos, tornando essencial a utilização de modelos estocásticos capazes de representar adequadamente sua dinâmica temporal e a incerteza inerente ao processo decisório. O custo operacional variável (C_t) é responsável por refletir os gastos anuais de operação e manutenção do sistema de produção já o preço do petróleo (P_t) representa a receita obtida pela comercialização do produto no mercado internacional. A dinâmica do custo operacional será modelada a partir de um **Movimento Geométrico Browniano** (MGB), enquanto o preço do petróleo será descrito pelo **modelo de dois fatores de Schwartz e Smith**, amplamente utilizado na literatura para representar a evolução estocástica dos preços de commodities.

2.4.1

Modelagem do Custo Operacional

O MGB é amplamente empregado na literatura financeira e em estudos de avaliação de projetos devido à sua simplicidade e robustez. O MGB permite capturar tanto a tendência média de crescimento ou decaimento de uma variável quanto sua dispersão ao longo do tempo, com um número reduzido de parâmetros. Matematicamente, um processo estocástico $C(t)$ é dito seguir um MGB se satisfaz a seguinte equação diferencial estocástica:

$$dC(t) = \alpha C(t) dt + \sigma C(t) dB(t), \quad (2-41)$$

onde α representa o termo de deriva (taxa média de crescimento do custo), σ é o parâmetro de volatilidade (medida de incerteza) e $dB(t)$ é um Movimento Browniano Padrão, também denominado processo de Wiener, com média zero e variância unitária, $\mathcal{N}(0, 1)$. A solução analítica da Equação 2-41 é dada por:

$$C(t) = C(0) \exp \left[\alpha t - \frac{1}{2} \sigma^2 t + \sigma B(t) \right], \quad (2-42)$$

onde $C(0)$ é o custo operacional inicial. Essa expressão mostra que o custo evolui de forma lognormal, incorporando uma tendência determinística (termo α) e uma componente aleatória (termo $B(t)$).

O parâmetro de *drift* α indica a tendência média de variação do custo ao longo do tempo. Quando $\alpha > 0$, o processo apresenta uma trajetória ascendente, refletindo um aumento esperado dos custos operacionais, por exemplo, devido à depleção do reservatório, elevação de custos de manutenção ou inflação setorial. Por outro lado, valores de $\alpha < 0$ representam uma

tendência de redução dos custos, possivelmente associada a ganhos de eficiência operacional ou adoção de novas tecnologias. O parâmetro de volatilidade σ mede o grau de incerteza do processo: valores mais altos de σ indicam maior dispersão nas trajetórias possíveis de $C(t)$ e, conseqüentemente, maior risco na estimativa de custos futuros.

A Figura 2.21 ilustra o comportamento do custo operacional variável ao longo de um horizonte de 10 anos, obtido a partir de simulações de Monte Carlo com 10.000 trajetórias estocásticas. Observa-se que, apesar da tendência média de crescimento moderado ($\alpha = 0,02$), volatilidade moderada ($\sigma = 0,1$) e $C(0) = \$10$ por barril, como sugerido por [19], há significativa dispersão entre as trajetórias. As curvas P10, média e P90 evidenciam a faixa de variação esperada dos custos operacionais, demonstrando a capacidade do MGB de capturar o risco associado à incerteza dessa variável econômica.




Figura 2.21: Evolução dos custos operacionais ao longo de 10 anos.

2.4.2

Modelagem do Preço do Petróleo

A incerteza nos preços do petróleo é uma fonte fundamental de risco na avaliação econômica de projetos de E&P. Modelos determinísticos tradicionais, modelos estocásticos de fator único e até mesmo, o amplamente utilizado MGB, frequentemente, não conseguem capturar toda a riqueza e complexidade do comportamento do preço real do petróleo, caracterizado por flutuações de curto prazo e tendências estruturais de longo prazo. Para representar melhor essas dinâmicas, temos o modelo de dois fatores introduzido por [20], que decompõe o logaritmo do preço do petróleo em componentes de curto e longo prazo.

No modelo de dois fatores de Schwartz e Smith [20], o componente de equilíbrio de longo prazo, denotado por ξ_t , é modelado como um MGB. Esse

fator representa a tendência persistente para a qual os preços do petróleo convergem, capturando fatores estruturais como inovação tecnológica, esgotamento das reservas, inflação e evolução das expectativas de mercado. O componente de curto prazo, denotado por χ_t , é modelado como um processo de Ornstein–Uhlenbeck com reversão à média, refletindo desvios temporários do equilíbrio causados por choques de mercado, eventos geopolíticos e desequilíbrios entre oferta e demanda. Sob a medida neutra ao risco, as dinâmicas do modelo de dois fatores são descritas pelo seguinte sistema de equações diferenciais estocásticas:

$$d\chi_t = (-\kappa\chi_t - \lambda_\chi) dt + \sigma_\chi dz_\chi, \quad (2-43)$$

$$d\xi_t = (\mu_\xi - \lambda_\xi) dt + \sigma_\xi dz_\xi, \quad (2-44)$$

onde:

- χ_t é o desvio de curto prazo em relação ao equilíbrio;
- ξ_t é o componente de equilíbrio de longo prazo;
- μ_ξ é o *drift* do fator de longo prazo;
- κ é a velocidade de reversão à média do fator de curto prazo;
- λ_χ e λ_ξ são os prêmios de risco associados aos fatores de curto e longo prazo, respectivamente;
- σ_χ e σ_ξ são as volatilidades dos fatores de curto e longo prazo, respectivamente;
- dz_χ e dz_ξ são incrementos correlacionados de processos de MGB, com $dz_\chi dz_\xi = \rho_{\chi\xi} dt$.

O logaritmo do preço do petróleo no tempo t é dado por:

$$\ln(P_t) = \chi_t + \xi_t, \quad (2-45)$$

e o preço à vista (*spot price*) é recuperado como:

$$P_t = \exp(\chi_t + \xi_t). \quad (2-46)$$

Para implementação numérica, as equações diferenciais estocásticas contínuas (2-43) e (2-44) são discretizadas da seguinte forma ([21], [22]):

$$\chi_{t+1} = \chi_t e^{-\kappa\Delta t} - (1 - e^{-\kappa\Delta t}) \frac{\lambda_\chi}{\kappa} + \sigma_\chi \varepsilon_\chi \sqrt{\frac{1 - e^{-2\kappa\Delta t}}{2\kappa}}, \quad (2-47)$$

$$\xi_{t+1} = \xi_t + (\mu_\xi - \lambda_\xi)\Delta t + \sigma_\xi \varepsilon_\xi \sqrt{\Delta t}, \quad (2-48)$$

onde ε_ξ e ε_χ são variáveis aleatórias normais padrão e Δt é o incremento de tempo. Conforme [23], se ε_ξ e ε são duas variáveis aleatórias padrão

independentes, é possível introduzir uma correlação entre os processos de preço descritos pelas Equações (2-47) e (2-48). Isso pode ser feito definindo a variável aleatória do segundo processo como:

$$\varepsilon_\chi = \varepsilon_\xi \rho_{\chi\xi} + \varepsilon \sqrt{1 - \rho_{\chi\xi}^2}, \quad (2-49)$$

onde $\rho_{\chi\xi}$ representa o coeficiente de correlação entre os dois processos.

Esse modelo permite capturar simultaneamente as volatilidades de curto prazo e as tendências de longo prazo observadas na dinâmica dos preços do petróleo. Ao adotar o modelo de dois fatores, a análise reproduz de forma mais precisa o comportamento estocástico dos preços históricos do petróleo, resultando em uma avaliação mais robusta para projetos de investimento em óleo e gás.

O modelo de preço do petróleo, conforme descrito acima, é caracterizado por sete parâmetros $(\kappa, \sigma_\xi, \sigma_\chi, \mu_\xi, \lambda_\chi, \lambda_\xi, \rho_{\chi\xi})$, além dos estados iniciais ξ_0 e χ_0 , que precisam ser estimados. Como esses parâmetros não são diretamente observáveis nos mercados de commodities, adota-se o procedimento de calibração proposto por [24], que utiliza o filtro de Kalman em conjunto com o método de máxima verossimilhança. O filtro de Kalman fornece estimativas recursivas dos parâmetros não observados ao gerar uma distribuição condicional posterior, considerando uma série temporal de preços à vista e futuros e a matriz de covariância de medição correspondente.

Para a calibração foram utilizados os preços médios anuais dos contratos futuros do petróleo tipo Brent no período de 3 de janeiro de 2000 a 7 de março de 2025. Especificamente, para cada ano, foram observados seis contratos futuros com vencimento em 1, 3, 5, 7, 9 e 13 meses. A Figura 2.22 apresenta os preços observados e os valores esperados simulados usando os parâmetros calibrados, e a Tabela 2.3, lista os parâmetros resultantes da calibração.




Figura 2.22: Calibração do modelo de SS para os preços do petróleo.

Tabela 2.3: Parâmetros calibrados para o modelo de SS.

Parâmetro	Valor	Parâmetro	Valor
χ_0	0.049	ξ_0	4.207
κ	3.771	μ_ξ	-0.161
σ_χ	0.287	σ_ξ	0.222
λ_χ	-0.202	λ_ξ	-0.092
$\rho_{\chi\xi}$	0.398		

Segundo [20], contratos futuros de longo prazo fornecem informações sobre o fator de longo prazo, enquanto contratos à vista e de curto prazo informam o fator de curto prazo. Usando o modelo de dois fatores, obtém-se uma solução analítica para o valor de um contrato futuro como:

$$\ln(F_{T,0}) = e^{-\kappa T} \chi_0 + \xi_0 + \mathcal{A}(T), \quad (2-50)$$

em que o termo de ajuste $\mathcal{A}(T)$ é definido como:

$$\mathcal{A}(T) = (\mu_\xi - \lambda_\xi)T - (1 - e^{-\kappa T}) \frac{\lambda_\chi}{\kappa} + \frac{1}{2} \left[(1 - e^{-2\kappa T}) \frac{\sigma_\chi^2}{2\kappa} + \sigma_\xi^2 T + 2(1 - e^{-\kappa T}) \frac{\rho_{\chi\xi} \sigma_\chi \sigma_\xi}{\kappa} \right]. \quad (2-51)$$

Nessa proposta de tese, empregou-se essa formulação juntamente com os parâmetros calibrados da Tabela 2.3 para calcular os preços futuros esperados do petróleo. A Figura 2.23 ilustra exemplos de trajetórias simuladas do preço do petróleo e respectivas faixas de confiança baseados em 10.000 simulações com preço inicial de \$70,62 o barril.




Figura 2.23: Simulações do preços do petróleo, intervalos de confiança e exemplos de trajetórias.

De acordo com [22], o modelo de dois fatores de Schwartz–Smith fornece uma representação mais realista do risco do preço do petróleo e da dinâmica esperada dos preços futuros, capturando com maior precisão tanto as incertezas quanto os caminhos prováveis dos preços. Por isso, é preferível para a modelagem da evolução dos preços do petróleo em comparação aos modelos clássicos.

2.4.3

Least Squares Monte Carlo

O método dos **Mínimos Quadrados de Monte Carlo** (em inglês, *Least Squares Monte Carlo* - LSM) é uma alternativa promissora na avaliação de projetos envolvendo opções reais em relação às abordagens tradicionais, como as técnicas de diferenças finitas e os modelos de árvores binomiais. Entre suas principais vantagens destacam-se a flexibilidade na avaliação, a capacidade de gerenciamento de risco e a determinação eficiente do momento ótimo de exercício em opções do tipo americana. De forma geral, o LSM oferece uma estrutura unificada para capturar o valor da flexibilidade gerencial em ambientes incertos e dinâmicos. Entre as aplicações típicas do método LSM, podemos citar:

- a avaliação de opções que dependem de múltiplos fatores de incerteza;
- a precificação de derivativos com características de opções americanas e dependentes do caminho;
- a valoração de opções cujas variáveis de estado seguem processos estocásticos gerais ou até mesmo processos não markovianos.

A ideia fundamental por trás do LSM está relacionada aos princípios da programação dinâmica. Em cada instante anterior ao vencimento de uma opção americana, o tomador da decisão compara o *payoff* obtido com o exercício antecipado com o valor esperado de continuação do projeto, de modo a escolher a alternativa que maximize o valor esperado. Assim, a estratégia ótima de exercício é determinada pela expectativa condicional do valor futuro da opção. Longstaff e Schwartz em [25] demonstraram que essa expectativa condicional pode ser estimada de maneira eficiente a partir de informações obtidas em simulações de Monte Carlo, utilizando uma regressão por mínimos quadrados. O método combina a flexibilidade das simulações estocásticas com a robustez estatística da regressão linear, permitindo aproximar a solução da programação dinâmica de forma prática e computacionalmente viável.

Em termos gerais, o método LSM é amplamente utilizado na avaliação de opções reais e financeiras com possibilidade de exercício antecipado. Conforme apresentado por [25], essa abordagem é atualmente considerada uma das mais eficientes para lidar com situações em que há múltiplas fontes de incerteza e dependência de caminho do ativo subjacente ([21], [26]). O objetivo do LSM é aproximar, trajetória a trajetória, a regra ótima de parada que maximiza o valor esperado de uma opção americana. Para ilustrar o procedimento, considere o caso em que o exercício é permitido apenas em um conjunto discreto de tempos K , $0 < t_1 \leq t_2 \leq \dots \leq t_K = T$. Determina-se, então, a decisão ótima de exercício em cada uma dessas datas. Embora as opções americanas possam ser exercidas a qualquer instante antes do vencimento, essa característica contínua pode ser representada de forma adequada escolhendo uma discretização temporal suficientemente fina (ou seja, um K grande), o que aproxima do problema contínuo. Em cada data potencial de exercício, é realizada uma regressão relacionando os valores simulados de continuação com funções das variáveis de estado, o que permite aproximar a expectativa condicional nesse determinado instante.

O procedimento pode ser resumido nas seguintes etapas ([25], [26]):

- (i) Gera-se um número suficientemente grande de trajetórias das variáveis incertas por meio de simulações de Monte Carlo;
- (ii) Em cada data de exercício, para as trajetórias nas quais a opção está *in the money*, realiza-se uma regressão dos valores de continuação futuros em função das variáveis de estado;
- (iii) As funções base do espaço de Hilbert das possíveis funções de continuação são escolhidas como polinômios ortogonais em L^2 ;

- (iv) O valor ajustado pela regressão é tomado como estimativa da expectativa condicional do valor de continuação, sendo comparado ao *payoff* imediato para decidir o exercício;
- (v) O procedimento é repetido recursivamente, de trás para frente, até o instante inicial.

O espaço das funções quadrado-integráveis L^2 , utilizado na regressão do LSM, constitui um espaço de Hilbert que admite uma base ortonormal. Neste trabalho utilizamos os polinômios de Laguerre como funções base, que são definidos por:

$$L_0(x) = \exp\left(-\frac{x}{2}\right), \quad (2-52)$$

$$L_1(x) = \exp\left(-\frac{x}{2}\right)(1-x), \quad (2-53)$$

$$L_2(x) = \exp\left(-\frac{x}{2}\right)\left(1-2x+\frac{x^2}{2}\right), \quad (2-54)$$

$$L_n(x) = \exp\left(-\frac{x}{2}\right) \frac{e^x}{n!} \frac{d^n}{dx^n} (x^n e^{-x}). \quad (2-55)$$

Com esses polinômios como base, a função valor de continuação $F(\omega; t_{k-1})$ pode ser aproximada por uma combinação linear dos mesmos:

$$F(\omega, t_{k-1}) = \sum_{j=0}^{\infty} a_j L_j(x), \quad (2-56)$$

em que a_j são coeficientes constantes. Outras famílias de polinômios ortogonais, como Hermite, Legendre, Jacobi ou Chebyshev, também podem ser utilizadas ([25]).

O método LSM apresenta vantagens relevantes em relação a outras técnicas, pois não é sensível à dimensionalidade do problema (número de fontes de incerteza) e tem sido amplamente utilizado na avaliação de opções reais na indústria de petróleo e gás, especialmente por sua capacidade de aproximar a programação dinâmica em problemas com múltiplas oportunidades de exercício ([26]).

Em cada instante de decisão t_k , o investidor pode exercer a opção e realizar o fluxo de caixa imediato conhecido, cujo valor é igual ao *payoff* correspondente. Já o valor de continuação envolve fluxos de caixa futuros incertos, não observáveis no instante da decisão. Sob o princípio da neutralidade ao risco, o valor de continuação é expresso pela expectativa do valor presente dos fluxos de caixa futuros descontados sob a medida neutra ao risco Q :

$$F(\omega; t_k) = \mathbb{E}_Q \left[\sum_{j=k+1}^K \exp\left(-\int_{t_k}^{t_j} r(\omega, s) ds\right) C(\omega, t_j; t_k, T) \middle| \mathcal{F}_{t_k} \right], \quad (2-57)$$

onde $r(\omega, t)$ é a taxa de desconto livre de risco (possivelmente estocástica), e a expectativa é condicional ao conjunto de informações $\mathcal{F}_{t_k}$ disponíveis em t_k . Essa abordagem conduz à formulação padrão da avaliação de opções reais: em cada ponto de decisão, o agente compara o valor de exercício imediato com o valor esperado da continuação. A política ótima consiste em exercer a opção sempre que o *payoff* imediato for positivo e exceder o valor esperado de esperar. [27] apresentou uma das primeiras aplicações do método LSM em um projeto de produção de petróleo simplificado, utilizando o estudo de caso desenvolvido por [19] e [28]. A análise incorporou tanto a opção de compra da participação do parceiro (*buyout*) quanto a opção de desinvestimento (*divest*) mediante um fluxo de caixa predeterminado. Esse problema, conhecido como *BDH problem*, foi revisitado e expandido por Nascimento et al em [29] demonstrando o valor da flexibilidade em projetos de E&P com opções reais utilizando LSM.

A simplicidade do método LSM, aliada à flexibilidade gerencial, torna-o particularmente adequado para ilustrar políticas ótimas e avaliar projetos sob incertezas, além de permitir fácil replicação e adaptação a outros contextos [26].

3

Aplicação de MLP e CNN na E&P

Nos últimos anos, a indústria de petróleo e gás tem passado por uma profunda transformação impulsionada pelos avanços em **Inteligência Artificial** (em inglês, Artificial Intelligence - AI) e **Aprendizado de Máquina** (em inglês, Machine Learning - ML). Tais ferramentas têm se mostrado promissoras para lidar com os desafios inerentes às grandes quantidades de dados gerados durante as etapas de exploração, avaliação e desenvolvimento de campos petrolíferos. O uso adequado dessas ferramentas possibilita uma interpretação mais robusta dos dados geológicos, geofísicos e de engenharia, contribuindo para a redução de incertezas e para a tomada de decisão orientada por dados.

Durante as campanhas de perfuração de poços exploratórios, o principal objetivo é reduzir a incerteza sobre o volume recuperável e a conectividade entre zonas produtoras. A aplicação de técnicas de ML permite correlacionar dados sísmicos e propriedades geológicas com resultados de poços já perfurados, criando modelos preditivos capazes de identificar as regiões mais promissoras para a perfuração de novos poços. Os algoritmos supervisionados, sendo um tipo de algoritmo de ML que aprende a partir de exemplos rotulados, são empregados para classificar litofácies, prever propriedades de reservatório e inferir a distribuição espacial de incertezas geológicas. Já os algoritmos não supervisionados, que não utiliza rótulos ou saídas conhecidas durante o treinamento, são amplamente utilizados para agrupar padrões de resposta sísmica e identificar zonas com comportamento geológico semelhante.

Além da caracterização, o aprendizado de máquina desempenha papel central na otimização na locação de poços. Modelos baseados em ML e técnicas de **Aprendizado Profundo** (em inglês, Deep Learning - DL) são capazes de integrar múltiplas fontes de dados (por exemplo, mapas de permeabilidade, pressão e porosidade), para identificar as posições que maximizam a produtividade e reduzem os custos de perfuração. Técnicas como **Aprendizado por Reforço** (em inglês, Reinforcement Learning - RL) e **Algoritmos Genéticos** têm sido aplicadas para explorar o espaço de decisão de forma adaptativa, buscando configurações ótimas de poços produtores e injetores sob múltiplas restrições operacionais e econômicas, sempre com o intuito de maximizar a produção.

O uso de AI em campanhas de delimitação e perfuração de poços representa um avanço significativo rumo à redução de riscos na indústria de E&P. A integração de ML com sistemas de gerenciamento de dados e modelos de simulação numérica oferece ganhos expressivos em eficiência, precisão e velocidade de processamento. Estudos recentes indicam que o número de publicações e aplicações de AI na indústria petrolífera cresceu, em média, 15% ao ano entre 2015 e 2024, refletindo o crescente interesse do setor ([34]). Esse avanço é particularmente evidente em conferências da *Society of Petroleum Engineers* (SPE), onde cerca de 40% dos trabalhos recentes abordam aplicações de AI e ML em problemas de caracterização, modelagem e otimização da produção.

Assim, a combinação entre AI e Métodos de Apoio à Decisão oferece um caminho promissor para o desenvolvimento de estratégias de avaliação mais eficientes, inteligentes e economicamente sustentáveis nos projetos de E&P ([35]).

3.1

Redes Neurais Artificiais

O cérebro humano é uma estrutura altamente complexa e eficiente, capaz de processar uma enorme quantidade de informações em tempo mínimo. Suas principais unidades de processamento são os neurônios, responsáveis pela recepção, transmissão e integração dos sinais que originam as funções cognitivas. A habilidade do cérebro em reconhecer padrões, tomar decisões e aprender com experiências passadas inspirou o desenvolvimento dos chamados sistemas inteligentes, entre eles as **Redes Neurais Artificiais** (em inglês, *Artificial Neural Networks* - ANN).

Diversos estudos em neurociência demonstram que o cérebro aprende por meio de experiências acumuladas ao longo da vida, ajustando suas conexões sinápticas conforme estímulos externos ([30]). Inspirados por esse mecanismo, pesquisadores da área de computação buscaram modelar matematicamente o funcionamento dos neurônios e de suas interconexões, criando sistemas artificiais capazes de aprender e generalizar informações.

Uma ANN é formada por um conjunto de neurônios interconectados, que influenciam uns aos outros e atuam de maneira conjunta como um sistema capaz de armazenar conhecimento adquirido a partir de exemplos apresentados. Dessa forma, a rede torna-se apta a realizar inferências e generalizar o aprendizado para novas situações ou exemplos ainda não observados.

O neurônio biológico é a célula fundamental do sistema nervoso e possui a função de transmitir informações entre diferentes regiões do corpo.

De acordo com [31], essa célula é composta por três partes principais: o soma (ou corpo celular), que contém o núcleo; os dendritos, que recebem os estímulos provenientes de outros neurônios; e o axônio, responsável por conduzir os impulsos elétricos até as terminações sinápticas. A comunicação entre neurônios ocorre nas sinapses, onde sinais elétricos e químicos são convertidos e transmitidos. Esses sinais elétricos representam a mensagem que percorre os neurônios, sendo a base da transmissão de informações no cérebro. Essa propagação é desencadeada pela ação de estímulos externos ou internos que modificam o potencial elétrico da membrana neuronal. A estrutura típica de um neurônio biológico pode ser observada na Figura 3.1 ([32]).




Figura 3.1: Modelo do neurônio biológico. Fonte [32].

A partir da estrutura e do comportamento dos neurônios biológicos, [33] propuseram o primeiro modelo matemático simplificado, conhecido como *Perceptron*, conforme Figura 3.2. Esse modelo descreve o neurônio artificial como uma unidade de processamento capaz de combinar sinais de entrada, ponderá-los e gerar uma saída de acordo com uma função de ativação.




Figura 3.2: Modelo do neurônio artificial. Fonte [30].

Matematicamente, um neurônio artificial k pode ser descrito pelo conjunto de equações:

$$u_k = \sum_{j=1}^m w_{kj} x_j, \quad (3-1)$$

$$v_k = u_k + b_k, \quad (3-2)$$

$$y_k = \varphi(v_k) \quad (3-3)$$

onde x_j representa os sinais de entrada, w_{kj} os pesos sinápticos associados a cada conexão, b_k é o termo de *bias* (responsável por deslocar o ponto de ativação) e $\varphi(\cdot)$ é a função de ativação que define a resposta do neurônio. O termo v_k é denominado *campo local induzido* e corresponde à soma ponderada das entradas mais o *bias*. A função de ativação $\varphi(\cdot)$ é responsável por limitar ou transformar o valor do campo induzido, determinando se o neurônio será ativado ou não. Segundo [30], esse processo é análogo ao comportamento “tudo ou nada” observado nos neurônios biológicos.

As funções de ativação desempenham papel essencial na modelagem de redes neurais, pois introduzem não linearidades que permitem ao sistema aprender relações complexas entre as variáveis de entrada e saída. As funções mais comuns encontradas na literatura são:

– **Função Degrau:**

$$\varphi(v) = \begin{cases} 1, & \text{se } v \geq 0 \\ 0, & \text{se } v < 0 \end{cases} \quad (3-4)$$

Representa o modelo binário de ativação, em que a saída assume apenas dois estados possíveis, ativado ou inativo.

– **Função Sigmoid:**

$$\varphi(v) = \frac{1}{1 + e^{-av}} \quad (3-5)$$

Essa função contínua e diferenciável permite uma transição suave entre 0 e 1, sendo amplamente utilizada em modelos de aprendizado supervisionado. A função sigmoide apresenta uma característica “S-shaped” e é ajustada pelo parâmetro a , que controla a inclinação da curva. Quando a tende a valores muito altos, o comportamento da sigmoide aproxima-se da função degrau.

– **Função ReLU:**

$$\varphi(v) = \max(0, v) \quad (3-6)$$

A função ReLU (Rectified Linear Unit) é uma das mais utilizadas em redes neurais profundas, pois introduz não linearidade mantendo simplicidade computacional. Ela anula valores negativos e mantém os positivos, o que reduz o problema de gradientes pequenos em camadas profundas, acelerando o treinamento.

– **Função Softmax:**

$$\varphi(v_i) = \frac{e^{v_i}}{\sum_{j=1}^n e^{v_j}} \quad (3-7)$$

A função Softmax é aplicada principalmente na camada de saída de classificadores multiclasse. Ela converte o vetor de entradas v_i em uma distribuição de probabilidades, onde a soma das saídas é igual a 1. Assim, cada saída pode ser interpretada como a probabilidade de pertencimento de uma amostra a uma classe específica.

A Figura 3.3 ilustra as curvas das funções de ativação definidas acima, evidenciando como cada uma das funções introduz diferentes graus de não linearidade na rede neural. Essas funções desempenham papel fundamental no mapeamento das entradas para as saídas e no comportamento do aprendizado da rede, influenciando na sua capacidade de generalização e convergência numérica.




Figura 3.3: Funções de ativação: (a) Degrau, (b) Sigmoid, (c) ReLU e (d) Softmax.

A semelhança observada entre as curvas das funções sigmoide e softmax pode ser explicada por sua relação matemática. A sigmoide é uma função univariada, ou seja, transforma um único valor real em um número entre 0 e 1, sendo utilizada em neurônios com saída binária, onde o objetivo é estimar a probabilidade de ocorrência de um evento. Já a softmax é uma função multivariada, que recebe um vetor de valores e os converte em uma distribuição de probabilidades cuja soma é igual a 1, sendo empregada em problemas de classificação multiclasse. Quando a softmax é aplicada em apenas duas classes, ela se reduz a uma forma equivalente à sigmoide, o que explica a semelhança visual entre seus gráficos no caso binário.

Uma ANN é uma estrutura de camadas onde vários *Perceptrons* são interconectados. A estrutura mais utilizada é o perceptron de múltiplas camadas (*Multilayer Perceptron - MLP*) formada por uma camada de entrada (não temos neurônios nessa camada, apenas os dados de entrada), uma ou mais camadas ocultas e uma camada de saída. As MLPs são redes totalmente conectadas, nas quais cada neurônio de uma camada está ligado a todos os neurônios da camada seguinte/anterior. A Figura 3.4 mostra a arquitetura de uma MLP com duas camadas ocultas e uma camada de saída.




Figura 3.4: Arquitetura de uma MLP com duas camadas ocultas. Fonte [30].

Treinar uma ANN requer ajustar os pesos w_{kj} da Equação 3-1 para minimizar a discrepância entre as saídas obtidas da rede e as saídas desejadas. O treinamento progride por meio da repetição do processo de propagação direta (cálculo das saídas) e da propagação reversa (atualização dos pesos) até que os critérios de treinamento sejam satisfeitos. Esses processos estabelecem o que conhecemos como algoritmo de retropropagação (*backpropagation algorithm*) que é baseado na regra de aprendizagem por correção do erro, consistindo basicamente de duas etapas:

- Forward propagation: os valores de entrada são propagados para frente, passando pelas camadas ocultas até a camada de saída, onde a rede produz uma resposta.
- Backpropagation: nessa etapa faz-se o ajuste dos pesos sinápticos, por meio do cálculo do erro realizado na camada de saída.

A Figura 3.5 ilustra uma porção de uma MLP, destacando os sinais presentes nesse tipo de rede. Temos os sinais funcionais (em preto), que se propagam no sentido direto e representam o fluxo normal das informações e os sinais de erro (em azul), que percorrem a rede no sentido oposto e, conforme dito anteriormente, são utilizados para ajustar os pesos sinápticos.




Figura 3.5: Direção dos fluxos de sinais em uma MLP. Fonte [30].

O algoritmo *backpropagation* utiliza a técnica de busca por gradiente para minimizar a função custo, cuja medida representa o desempenho da aprendizagem. Como mostrado no Algoritmo 1, o processo de treinamento é iterativo e ajusta os pesos até que a condição de parada seja atingida. Mais detalhes do algoritmo e dos cálculos matemáticos podem ser encontrados na referência [30].

Algoritmo 1 Algoritmo *Backpropagation*

- 1: **begin**
 - 2: Atribuição de valores iniciais aos pesos sinápticos;
 - 3: **repeat**
 - 4: Apresentação à rede dos padrões de entrada e as saídas desejadas;
 - 5: Cálculo dos valores de saída dos neurônios ocultos;
 - 6: Cálculo dos valores de saída dos neurônios de saída (resposta da rede);
 - 7: Cálculo do erro (diferença entre a resposta da rede e o valor esperado);
 - 8: Ajuste dos pesos sinápticos;
 - 9: **until** Condição de parada *não satisfeita*;
 - 10: **end**
-

As relações obtidas para o algoritmo de retropropagação são apresentadas a seguir. A Equação 3-8 fornece a correção do peso $\Delta w_{ji}(n)$, que é aplicada ao peso sináptico que conecta o neurônio i ao neurônio j [30]:

$$\begin{pmatrix} \text{Correção} \\ \text{do peso} \end{pmatrix} = \begin{pmatrix} \text{Taxa} \\ \text{de aprendizagem} \end{pmatrix} \cdot \begin{pmatrix} \text{Gradiente} \\ \text{local} \end{pmatrix} \cdot \begin{pmatrix} \text{Sinal de entrada} \\ \text{do neurônio } j \end{pmatrix}$$

$$\Delta w_{ji}(n) = \eta \cdot \delta_j(n) \cdot y_i(n) \quad (3-8)$$

O gradiente local $\delta_j(n)$ depende se o neurônio j é um nó de saída ou se é um nó oculto. Conforme o caso, temos:

- (i) Se o neurônio j é um nó de saída, $\delta_j(n)$ é igual ao produto da derivada $\varphi'_j(v_j(n))$ pelo sinal de erro $e_j(n) = d_j(n) - y_j(n)$, ambos associados ao

neurônio j :

$$\delta_j(n) = e_j(n) \varphi'_j(v_j(n)) \quad (3-9)$$

- (ii) Se o neurônio j é um nó oculto, $\delta_j(n)$ é igual ao produto da derivada associada $\varphi'_j(v_j(n))$ pela soma ponderada dos δ s calculados para os neurônios na próxima camada oculta ou camada de saída que estão conectados ao neurônio j :

$$\delta_j(n) = \varphi'_j(v_j(n)) \sum_k \delta_k(n) w_{kj}(n) \quad (3-10)$$

Os ajustes dos pesos sinápticos é a parte fundamental do algoritmo *backpropagation*. Em qualquer camada, os valores dos pesos w_{ji} na iteração n serão ajustados da seguinte forma:

$$w_{ji}(n) = w_{ji}(n-1) + \Delta w_{ji}(n) \quad (3-11)$$

Para que uma MLP apresente bom desempenho em aplicações práticas, é fundamental definir uma configuração adequada de seus parâmetros. Essa configuração depende das características específicas do problema, como o tipo dos dados de entrada, a quantidade de amostras disponíveis para treinamento e teste e a dimensionalidade do conjunto de dados. Em geral, a determinação dos valores ideais para os parâmetros da rede é um processo desafiador, visto que esses valores não são diretamente observáveis nem de fácil obtenção.

Segundo [36], muitos desses parâmetros são ajustados por meio de um processo de tentativa e erro, no qual diferentes combinações são testadas e avaliadas até que se encontre a configuração que produz os melhores resultados. Entre os parâmetros mais sensíveis ao desempenho da MLP destacam-se a taxa de aprendizagem, o número de camadas ocultas e a quantidade de neurônios em cada uma delas, os quais exercem forte influência na capacidade de generalização e na estabilidade do treinamento.

3.2

Redes Neurais Convolucionais

Uma rede neural profunda (*Deep Neural Network* - DNN) pode ser entendida como uma MLP de múltiplas camadas ocultas, configurada em uma estrutura feedforward. Inspiradas na organização do córtex visual humano, essas redes processam os sinais de entrada de forma hierárquica, passando por diversas camadas responsáveis por extrair representações progressivamente mais abstratas dos dados.

Com os avanços tecnológicos, especialmente o uso de unidades de processamento gráfico (*Graphics Processing Unit* - GPU), tornou-se possível treinar redes com dezenas ou até centenas de camadas, graças à execução paralela de

um grande número de operações matriciais. Exemplos notáveis incluem a AlexNet, composta por 8 camadas; a VGGNet, com versões de 16 e 19 camadas; e a ResNet, que pode atingir até 152 camadas.

Entretanto, o aspecto mais relevante das redes neurais profundas não é apenas a profundidade em termos de número de camadas, mas também a introdução de novos operadores que não eram utilizados nas MLPs tradicionais. Entre esses operadores destacam-se a convolução, o pooling e o flattening, discutidos nessa seção. Em virtude da presença das camadas de convolução, essas arquiteturas são conhecidas como redes neurais convolucionais (*Convolutional Neural Networks* - CNN).

4

Estado da arte

5

Resultados preliminares

6

Próximos Passos

Projetos de Exploração e Produção (E&P) envolvem elevada incerteza geológica e de mercado. Métodos tradicionais de avaliação, como o Fluxo de Caixa Descontado, não capturam o valor da flexibilidade gerencial. Nesse contexto, o **Valor da Informação** (VoI) quantifica os benefícios de reduzir incertezas, enquanto as **Opções Reais** (ROA) avaliam a flexibilidade de adiar, expandir ou abandonar projetos.

7

Conclusão

Um sistema de microscopia digital com reconhecimento e classificação automática dos cristais de hematita em minérios de ferro foi desenvolvido.

O método utiliza operações tradicionais de processamento digital de imagens e propõe uma segmentação automática de cristais baseada no cálculo da distância espectral, a fim de controlar ...

É fundamental também comentar que ...

Assim, como uma proposta para trabalho futuro, pode-se buscar combinar os dois enfoques...

Referências Bibliográficas

- [01] BRATVOLD, R. B.; BEGG, S. H. **Making Good Decisions**. Society of Petroleum Engineers, Richardson, TX, 1st edition, 2010.
- [02] HOWARD, R. A. **Speaking of decisions: Precise decision language**. *Decision Analysis*, 2:71–78, 2004.
- [03] BRATVOLD, R. B.; BICKEL, J. E.; LOHNE, H. P. **Value of information in the oil and gas industry: Past, present, and future**. *SPE Reservoir Evaluation & Engineering*, 12:630–638, 2009.
- [04] BICKEL, J. E. **The relationship between perfect and imperfect information in a two-action risk-sensitive problem**. *Decision Analysis*, 5:116–128, 2008.
- [05] PRATT, J. W.; RAIFFA, H.; SCHLAIFER, R. **Introduction to Statistical Decision Theory**. The MIT Press, Cambridge, MA, 1st edition, 1995.
- [06] DIAS, M. A. G. **Opções Reais Híbridas com Aplicações em Petróleo**. Tese de doutorado, PUC-Rio, Rio de Janeiro, 2005.
- [07] PINTO, J. R.; AGUIAR, J. C.; MORAIS, F. S. **The value of information from time-lapse seismic data**. *The Leading Edge*, 5:572–576, 2011.
- [08] LOPES, Y. G.; ALMEIDA, A. T. **Assessment of synergies for selecting a project portfolio in the petroleum industry based on a multi-attribute utility function**. *Journal of Petroleum Science and Engineering*, 126:131–140, 2015.
- [09] EIDSVIK, J.; MUKERJI, T.; BHATTACHARJYA, D. **Value of Information in the Earth Sciences**. Cambridge University Press, Cambridge, UK, 1st edition, 2015.
- [10] BICKEL, J. E.; SMITH, J. E. **Optimal sequential exploration: A binary learning model**. *Decision Analysis*, 3:16–32, 2006.
- [11] MOROSOV, A. L. **Sequential drilling decisions based on explicit joint probability distribution of spatially distributed subsurface data**. Phd thesis, University of Stavanger, Stavanger, Norway, 2024.

- [12] MOROSOV, A. L.; BRATVOLD, R. B. **Appraisal campaign selection based on the maximum value of sequential information.** *Journal of Petroleum Science and Engineering*, 208:1–13, 2022.
- [13] BELMAN, R. E. **Dynamic Programming.** Princeton University Press, Princeton, NJ, 1957.
- [14] MOROSOV, A. L.; BRATVOLD, R. B. **Drilling-campaign optimization using sequential information and policy analytics.** *SPE Journal*, 26:3609–3625, 2021.
- [15] BRATVOLD, R. B.; THOMAS, P. **Robust discretization of continuous probability distributions for value-of-information analysis.** In: *INTERNATIONAL PETROLEUM TECHNOLOGY CONFERENCE*, p. 1–22, Kuala Lumpur, Malaysia, 2008.
- [16] BEGG, S. H.; BRATVOLD, R. B. **The value of flexibility in managing uncertainty in oil and gas investments.** *SPE Annual Technical Conference and Exhibition*, San Antonio, TX, p. SPE-77586-MS, 2002.
- [17] VAN ESSEN, G. M.; ZANDVLIET, M. J.; VAN DEN HOF, P. M. J.; BOSGRA, O. H.; JANSEN, J. D. **Robust waterflooding optimization of multiple geological scenarios.** *SPE Journal*, 14:202–210, 2009.
- [18] JANSEN, J. D.; FONSECA, R. M.; KAHROBAEI, S.; SIRAJ, M. M.; VAN ESSEN, G. M.; VAN DEN HOF, P. M. J. **The egg model - a geological ensemble for reservoir simulation.** *Geoscience Data Journal*, 1:192–195, 2014.
- [19] BRANDÃO, L. E.; DYER, J. S.; HAHN, W. **Using binomial decision trees to solve real-option valuation problems.** *Decision Analysis*, 2:69–88, 2005.
- [20] SCHWARTZ, E.; SMITH, J. E. **Short-term variations and long-term dynamics in commodity prices.** *Management Science*, 46:893–911, 2000.
- [21] THOMAS, P.; BRATVOLD, R. B. **A real options approach to the gas cap blowdown decision.** *SPE Annual Technical Conference and Exhibition*, Houston, TX, p. SPE-174868-MS, 2015.
- [22] FEDOROV, S.; HAGSPIEL, V.; LERDAHL, T. **Real options approach for a staged field development with optional wells.** *Journal of Petroleum Science and Engineering*, 205:1–21, 2021.

- [23] WIERSEMA U. F. **Brownian Motion Calculus**. John Wiley & Sons, West Sussex, UK, 1st edition, 2008.
- [24] GOODWIN, D. **Schwartz-Smith Two-Factor Model in the Copper Market: before and after the New Market Dynamics**. Master thesis, School of Economics and Management - Lund University, Sweden, 2013.
- [25] LONGSTAFF, F. A.; SCHWARTZ, E. S. **Valuing american options by simulation: A simple least-squares approach**. *The Review of Financial Studies*, 14:113–147, 2001.
- [26] AHMADI, R.; BRATVOLD, R. B. **An exposition of least square monte carlo approach for real options valuation**. *Journal of Petroleum Science and Engineering*, 222:111230, 2023.
- [27] SMITH, J. E. **Alternative approaches for solving real-options problems (comment on brandão et al. 2005)**. *Decision Analysis*, 2:89–102, 2005.
- [28] BRANDÃO, L. E.; DYER, J. S.; HAHN, W. **Response to comments on brandão et al**. *Decision Analysis*, 2:103–109, 2005.
- [29] NASCIMENTO, W.; BRATVOLD, R.; DIAS, M.; PACHECO, M. **Real options approach to valuation and decision-making of E&P projects under geological and market uncertainties**. *Manuscrito em preparação*, 2025.
- [30] HAYKIN, S. **Neural Networks and Learning Machines**. Pearson Prentice Hall, Upper Saddle River, NJ, 3rd edition, 2009.
- [31] ARBIB, M. A. **The Handbook of Brain Theory and Neural Networks**. The MIT Press, London, UK, 2nd edition, 2002.
- [32] ANANTHASWAMY, A. **Why Machines Learn: The Elegant Maths Behind Modern AI**. Allen Lane, London, UK, 1st edition, 2024.
- [33] MCCULLOCH, W. S.; PITTS, W. H. **A logical calculus of the ideas immanent in nervous activity**. *Bulletin of Mathematical Biophysics*, 5:115–133, 1943.
- [34] PÓVOAS, M. S.; MOREIRA, J. F.; NETO, S. V. M.; CARVALHO, C. A. S.; CEZARIO, B. S.; GUEDES, A. L. A.; LIMA, G. B. A. **Artificial intelligence in the oil and gas industry: Applications, challenges, and future directions**. *Applied Sciences*, 15:1–16, 2025.

- [35] SIRCAR, A.; YADAV, K.; RAYAVARAPU, K.; BIST, N.; OZA, H. **Application of machine learning and artificial intelligence in oil and gas industry**. *Petroleum Research*, 6:379–391, 2021.
- [36] BASHEER, I. A.; HAJMEER, M. **Artificial neural networks: fundamentals, computing, design, and application**. *Journal of Microbiological Methods*, 43:3–31, 2000.